

École Centrale Nantes
3^{ème} année du cycle ingénieur – Option DATASIM

Rapport de stage de fin d'étude

Identification de déterminants de la marche de nuit en ville par l'examen de la déviation de traces piétonnes au plus court chemin

Oussama Nair

Stage réalisé au sein du laboratoire
Ambiances Architectures Urbanités (AAU) – CRENAU
École Nationale Supérieure d'Architecture de Nantes

Encadrants :

Thomas Leduc – AAU / CRENAU
Florian Massuyeau – AAU / CRENAU
Roland Brémond – Université Gus-
tave Eiffel

Jury :

Mira Rizkallah
Présidente du jury
Sébastien Bourguignon
Rapporteur

Année universitaire 2025–2026

Remerciements

Je tiens tout d'abord à remercier l'ensemble des personnes qui ont contribué au bon déroulement de ce stage et à la réalisation de ce travail.

Je souhaite adresser mes sincères remerciements à mes encadrants, **Thomas Leduc, Florian Massuyeau et Roland Brémond**, pour leur accompagnement, leur disponibilité et leurs conseils tout au long de ce stage. Je les remercie également pour les échanges scientifiques et les discussions qui ont permis de faire évoluer et d'enrichir ce travail.

Je remercie également l'ensemble des enseignants de l'option **DATASIM de Centrale Nantes** pour la qualité de leur enseignement et pour les connaissances acquises au cours de cette formation, qui ont constitué une base importante pour la réalisation de ce stage.

Je souhaite également remercier les membres du laboratoire pour leur accueil et pour l'environnement de travail qui m'a permis d'évoluer dans un cadre scientifique enrichissant.

Enfin, je tiens à remercier tout particulièrement **ma famille et mes parents** pour leur soutien constant, leurs encouragements et leur confiance tout au long de mon parcours. Leur présence et leur soutien ont été essentiels dans la réalisation de ce projet et dans les différentes étapes de ma formation.

Abstract

This internship focuses on the study of the relationships between pedestrian trajectories and urban environmental characteristics, with particular attention to nighttime walking. The objective is to identify environmental characteristics associated with differences between daytime and nighttime pedestrian movements.

A complete processing pipeline was developed from GPS trajectory data, including trajectory preprocessing and filtering, day/night classification, exploratory clustering and map matching onto a pedestrian network derived from OpenStreetMap. An environmental *feature space* was then constructed using data describing buildings, public lighting and the morphology of the urban environment.

The analysis conducted on data from Paris and London highlights, in particular, differences in the *Sky View Factor* between daytime and nighttime trajectories. Daytime trajectories show higher `svf_geom` values in both cities, suggesting an association with environments characterized by greater visual openness.

These results remain exploratory and must be interpreted in light of the limitations of the data, including the limited number of nighttime trajectories, selection bias associated with collaborative data and losses during the map matching process. Nevertheless, the work provides a methodological basis for further investigating the relationships between nighttime pedestrian mobility and the urban environment.

Keywords : pedestrian trajectories, nighttime walking, GPS, map matching, OpenStreetMap, urban environment, Sky View Factor, pedestrian mobility.

Table de matières

Remerciements² Abstract³

1	Introduction	6
1.1	Présentation du laboratoire	6
1.2	Contexte du projet	7
1.2.1	Enjeux de l'éclairage urbain nocturne	7
1.2.2	Mobilité piétonne nocturne	7
1.2.3	Problématique scientifique	7
1.2.4	Objectifs du stage	8
1.2.5	Structure du projet et déroulement du travail	9
2	État de l'art et fondements théoriques	10
2.1	Données de localisation et représentation spatiale	10
2.1.1	Systèmes GNSS et données de trajectoires	10
2.1.2	Systèmes de coordonnées et projections cartographiques	11
2.2	Analyse et traitement des trajectoires	12
2.2.1	Prétraitement des trajectoires	12
2.2.2	Simplification géométrique des trajectoires	12
2.2.3	Descripteurs des trajectoires	13
2.2.4	Détermination des traces de jour et nocturnes	14
2.3	Regroupement et comparaison des trajectoires	14
2.3.1	Principe du clustering	15
2.3.2	Regroupement selon les couples origine-destination	15
2.3.3	Comparaison géométrique des trajectoires	16
2.3.4	Dynamic Time Warping	16
2.3.5	Approches explorées dans le projet	17
2.4	Map matching	18
2.4.1	Approches géométriques par projection	18
2.4.2	Map matching par modèle de Markov caché	18
2.4.3	Méthode utilisée dans le projet	21
2.5	Caractérisation de l'environnement urbain	21
2.5.1	Représentation du bâti	21
2.5.2	Hauteur et morphologie urbaine	22
2.5.3	Éclairage public	22
2.5.4	Visibilité et isovistes	22
2.5.5	Sky View Factor	22
2.5.6	Indicateurs morphologiques issus des rayons de visibilité	23

3 Données et zones d'étude	24
3.1 Zones d'étude	24
3.1.1 Paris	24
3.1.2 Londres	25
3.1.3 Pékin	25
3.2 Sources de données	26
3.2.1 OpenStreetMap	27
3.2.2 Données GPX	28
3.2.3 BD TOPO®	28
3.2.4 GlobalBuildingAtlas	29
3.2.5 Données d'éclairage public	29
3.2.6 GeoLife	29
3.2.7 Outdoorvision	30
3.3 Données de trajectoires	30
3.3.1 Extraction et reconstruction	30
3.3.2 Statistiques des trajectoires	31
3.4 Difficultés liées aux données	32
3.5 Harmonisation des données	33
4 Exploration et analyse préliminaire des trajectoires	34
4.1 Analyse des caractéristiques temporelles des trajectoires	34
4.2 Analyse de la distribution des vitesses	35
5 Prétraitement et construction des trajectoires	37
5.1 Extraction et reconstruction des trajectoires	37
5.2 Nettoyage et cohérence temporelle	38
5.3 Segmentation et filtrage des trajectoires	38
5.4 Classification des trajectoires selon la période	39
6 Map matching	40
6.1 Introduction	40
6.2 Construction du réseau piéton	41
6.3 Justification du choix du HMM	42
6.4 Paramétrage et stratégie de recalage	43
6.5 Application aux trajectoires	44
6.6 Résultats du map matching	44
6.7 Limites du map matching	45

1 Introduction

1.1 Présentation du laboratoire

Le stage a été réalisé au sein de l'École Nationale Supérieure d'Architecture de Nantes (ENSA Nantes), dans l'équipe nantaise du laboratoire *Ambiances Architectures Urbanités* (AAU), le Centre de Recherche Nantais Architectures Urbanités (CRENAU).

Le laboratoire AAU est une unité mixte de recherche qui associe plusieurs établissements et qui développe des recherches autour des relations entre les ambiances, l'architecture et les environnements urbains. Il est organisé autour de deux équipes : le CRENAU, situé à l'ENSA Nantes, et le CRESSON, situé à l'ENSA Grenoble. Les travaux du laboratoire portent notamment sur les différentes dimensions des ambiances urbaines, parmi lesquelles les dimensions visuelle, lumineuse, sonore, thermique et kinesthésique.

Le CRENAU constitue l'équipe nantaise du laboratoire AAU. Il est issu de la fusion, en 2015, du Centre de Recherche Méthodologique d'Architecture (CERMA) et du laboratoire Langages, Actions Urbaines, Altérités (LAUA). Cette équipe développe des recherches interdisciplinaires portant notamment sur l'architecture, les formes urbaines, les usages et les expériences des environnements construits.

L'environnement scientifique du CRENAU est ainsi particulièrement adapté à l'étude des interactions entre les individus et leur environnement urbain. Les recherches menées au sein de l'équipe mobilisent des approches issues de plusieurs disciplines et s'appuient sur des méthodes d'observation, de modélisation, de simulation et d'analyse de données. Le laboratoire dispose également de différentes plateformes et ressources permettant d'étudier les expériences sensibles des environnements construits.

C'est dans cet environnement de recherche interdisciplinaire que s'est inscrit le présent stage. Le travail réalisé porte plus spécifiquement sur l'analyse de trajectoires piétonnes et sur l'étude des relations entre les déplacements nocturnes et les caractéristiques de l'environnement urbain. Cette thématique s'inscrit ainsi à l'intersection de plusieurs domaines mobilisés au sein du CRENAU, notamment l'étude des ambiances urbaines, l'analyse des mobilités et l'utilisation de méthodes numériques pour la caractérisation des espaces urbains.

Le stage a ainsi permis de mettre en œuvre une approche combinant analyse de données géographiques, traitement de trajectoires, modélisation du réseau piéton et caractérisation numérique de l'environnement urbain, dans un contexte de recherche appliquée aux problématiques de mobilité et d'urbanité.

“

1.2 Contexte du projet

1.2.1 Enjeux de l'éclairage urbain nocturne

La période nocturne constitue un contexte particulier pour les déplacements en ville, notamment en raison des conditions de visibilité et d'éclairage différentes de celles rencontrées durant la journée. L'éclairage artificiel joue ainsi un rôle important dans les conditions de mobilité et dans la perception de l'environnement urbain[10][12][13].

Cependant, son utilisation nocturne soulève également des enjeux énergétiques et environnementaux. Le projet LUNNE (*La Lumière la Nuit Nuit à l'Environnement*)[2], financé par l'Agence Nationale de la Recherche (ANR-22-CE22-0004), s'intéresse notamment aux conditions permettant de réduire l'éclairage artificiel nocturne tout en maintenant des conditions acceptables pour les usagers.

Cette problématique implique de considérer l'éclairage en relation avec les autres caractéristiques de l'environnement urbain. La morphologie du bâti, la visibilité et la configuration des espaces peuvent notamment contribuer à modifier les conditions dans lesquelles les individus se déplacent la nuit. L'étude de ces interactions constitue ainsi un enjeu pour mieux comprendre les comportements de mobilité nocturne.

1.2.2 Mobilité piétonne nocturne

La mobilité piétonne est particulièrement intéressante dans l'étude de l'environnement nocturne. Le piéton se déplace directement dans l'espace urbain et reste donc en contact avec les caractéristiques des rues qu'il traverse[12]. La forme du réseau, les bâtiments, leur hauteur, l'ouverture de l'espace ou encore l'éclairage peuvent ainsi décrire une partie de l'environnement dans lequel se déroule le déplacement.[14]

L'étude des déplacements piétons nécessite donc de mettre en regard les trajectoires observées et les caractéristiques des espaces traversés. Les traces GPS permettent de retrouver les itinéraires réellement suivis et d'observer leur répartition dans la ville. Elles donnent cependant avant tout une information de position. Pour aller plus loin, ces trajectoires doivent être associées à des données permettant de décrire leur environnement urbain.

1.2.3 Problématique scientifique

L'analyse des trajectoires piétonnes permet d'étudier les déplacements réalisés dans l'espace urbain. Une trajectoire GNSS indique cependant principalement la position du piéton et ne permet pas d'expliquer directement le

choix d'un itinéraire. Cette question est particulièrement intéressante la nuit, lorsque les conditions de visibilité et de perception de l'espace changent.

Ce travail met en relation les trajectoires piétonnes et les caractéristiques des espaces traversés. Les trajectoires sont nettoyées et filtrées, puis recalées sur un réseau piéton. Leur environnement est décrit à partir de données sur le bâti, la hauteur des bâtiments, l'éclairage public et la visibilité.

La problématique est la suivante :

Dans quelle mesure les caractéristiques de l'environnement urbain sont-elles associées aux déplacements des piétons la nuit, notamment à leurs choix de trajectoire ?

L'analyse repose sur le traitement des trajectoires, le *map matching*, l'analyse exploratoire et la caractérisation de l'environnement urbain.

1.2.4 Objectifs du stage

L'objectif général de ce travail est d'étudier les relations entre les trajectoires piétonnes et les caractéristiques de l'environnement urbain, avec une attention particulière portée aux déplacements nocturnes.

Pour répondre à cette problématique, plusieurs objectifs ont été définis :

- Construire un jeu de données de trajectoires piétonnes exploitables à partir de données GPS hétérogènes, en réalisant leur nettoyage et leur filtrage ;
- Identifier les itinéraires empruntés par les piétons en recalant les trajectoires sur le graphe piéton issu d'OpenStreetMap ;
- Caractériser l'environnement urbain autour des trajectoires à partir des données de bâtiments, de leur hauteur, de l'éclairage public et de différents indicateurs de visibilité ;
- Explorer la structure des trajectoires à travers différentes analyses exploratoires et méthodes de regroupement, afin d'identifier d'éventuels comportements ou profils de déplacement similaires ;
- Analyser les différences entre les déplacements de jour et nocturnes et étudier l'association entre les caractéristiques de l'environnement urbain et les comportements observés la nuit.

L'ensemble de ces étapes vise à mettre en place une méthodologie reproductible permettant d'analyser les déterminants environnementaux de la mobilité piétonne nocturne à partir de données de trajectoires.

1.2.5 Structure du projet et déroulement du travail

Le travail réalisé au cours de ce stage s'est déroulé selon plusieurs étapes successives. Une première phase a été consacrée à une recherche bibliographique portant notamment sur la marchabilité, la mobilité piétonne nocturne, l'analyse de trajectoires et les méthodes de caractérisation de l'environnement urbain. Cette étude de la littérature a permis de préciser la problématique, d'identifier les principales approches existantes et d'orienter les choix méthodologiques.

Une deuxième phase a consisté à identifier et collecter les différentes sources de données nécessaires à l'étude.

Les données de trajectoires ont ensuite fait l'objet d'une phase de prétraitement et d'analyse exploratoire, afin d'obtenir un jeu de données exploitable et de mieux comprendre les caractéristiques des déplacements. Différentes approches ont également été testées pour analyser la structure des trajectoires, notamment des méthodes de regroupement selon les couples origine-destination et des méthodes fondées sur leur similarité.

Une étape de recalage des trajectoires sur le réseau piéton a ensuite permis d'identifier les itinéraires effectivement empruntés. Les trajectoires obtenues ont été mises en relation avec différentes sources décrivant leur environnement urbain, afin d'extraire des caractéristiques liées notamment au bâti, à l'éclairage et à la visibilité.

Enfin, les données ainsi construites ont été utilisées pour analyser les déplacements et étudier les relations entre les caractéristiques de l'environnement urbain et les comportements observés. L'ensemble de ces étapes a été réalisé de manière itérative, les résultats des analyses exploratoires ayant notamment permis d'orienter les étapes méthodologiques suivantes.

Une dernière phase a été consacrée à la documentation technique du travail réalisé. Elle comprend notamment la structuration du projet, la documentation des différentes étapes du pipeline, la description des sources de données et des paramètres utilisés, ainsi que la préparation de la documentation nécessaire à la reproductibilité et à la réutilisation du pipeline pour différentes villes. Le rapport suit cette progression. Après la présentation de la littérature et des données utilisées, les différentes étapes de préparation et d'exploration des trajectoires sont détaillées. Les méthodes de recalage et de caractérisation de l'environnement urbain sont ensuite présentées, avant d'aborder les analyses finales, leurs résultats, leurs limites et les perspectives du travail. La documentation technique produite dans le cadre du projet est également présentée comme un élément de valorisation et de reproductibilité du travail.

2 État de l'art et fondements théoriques

L'étude des trajectoires piétonnes combine plusieurs étapes. Les données GNSS permettent de reconstruire les déplacements à partir de positions géographiques et temporelles, après leur nettoyage et leur structuration. Le *map matching* permet ensuite de les associer au réseau urbain, notamment à l'aide de modèles de Markov cachés.

Les trajectoires peuvent également être comparées ou regroupées à l'aide de méthodes de *clustering* et de mesures de similarité telles que la *Dynamic Time Warping*. Enfin, les caractéristiques de l'environnement urbain peuvent être décrites à partir de données sur le bâti, l'éclairage et la visibilité, notamment avec le *Sky View Factor* (SVF) et les [18].

Ce chapitre présente les principaux concepts et méthodes mobilisés dans le cadre de cette étude. Il introduit d'abord les données de localisation et leur représentation spatiale, puis les méthodes de traitement et de comparaison des trajectoires, avant de présenter les approches de *map matching*. La dernière partie est consacrée aux méthodes de caractérisation morphologique et visuelle de l'environnement urbain. Les méthodes effectivement mises en œuvre dans le cadre du projet seront ensuite détaillées en précisant leur principe, leur paramétrage et leur utilisation.

2.1 Données de localisation et représentation spatiale

2.1.1 Systèmes GNSS et données de trajectoires

Les systèmes de positionnement par satellites[19], regroupés sous le terme GNSS (*Global Navigation Satellite System*), permettent d'estimer la position d'un récepteur à partir des signaux émis par plusieurs satellites. Le système GPS (*Global Positioning System*), développé par les États-Unis, constitue l'un des systèmes GNSS les plus largement utilisés, aux côtés notamment de Galileo, GLONASS et BeiDou.

Le principe général du positionnement repose sur la mesure du temps de propagation des signaux entre les satellites et le récepteur. À partir de plusieurs satellites dont les positions sont connues, le récepteur peut estimer sa position dans l'espace. Une succession de positions enregistrées au cours du temps permet alors de représenter le déplacement d'un individu sous la forme d'une trajectoire.

Dans le contexte de la mobilité piétonne, ces données présentent plusieurs sources d'incertitude. La précision du positionnement peut notamment être af-

fectée par les obstacles physiques, les bâtiments, les phénomènes de réflexion ou de diffusion des signaux, ainsi que par la configuration des satellites visibles. Ces erreurs peuvent produire des positions légèrement décalées par rapport au déplacement réellement effectué et doivent être prises en compte lors de l'analyse des trajectoires.

Une trajectoire peut ainsi être représentée comme une séquence ordonnée d'observations :

$$T = \{(x_i, y_i, t_i)\}_{i=1}^n, \quad (1)$$

où (x_i, y_i) représente la position spatiale de l'observation i , t_i son horodatage et n le nombre total d'observations de la trajectoire.

Cette représentation permet d'extraire différentes informations relatives au déplacement, telles que sa durée, sa longueur, sa vitesse ou encore son évolution spatiale. Elle constitue également la base des étapes ultérieures de traitement, notamment le filtrage, le recalage sur un réseau et la caractérisation de l'environnement traversé.

2.1.2 Systèmes de coordonnées et projections cartographiques

Les données géographiques peuvent être exprimées dans différents systèmes de coordonnées de référence, ou CRS (*Coordinate Reference System*). Un CRS définit notamment la manière dont les positions sont représentées sur la surface terrestre et permet d'établir une correspondance entre les coordonnées numériques et leur localisation géographique.

Les coordonnées géographiques sont généralement exprimées en latitude et longitude sur un ellipsoïde de référence. Elles sont adaptées à la localisation globale, mais les calculs de distances directement réalisés dans ce système peuvent être inadaptés pour des analyses métriques locales. Les systèmes de coordonnées projetées permettent au contraire de représenter une zone de la surface terrestre dans un plan et sont particulièrement adaptés aux opérations géométriques locales.

Dans le cadre d'une analyse multi-ville, le système de coordonnées doit également être adapté à chaque zone d'étude. Les différentes sources de données doivent être transformées vers un CRS commun avant leur combinaison spatiale, afin d'éviter des décalages géométriques ou des calculs de distance incohérents.

2.2 Analyse et traitement des trajectoires

Les trajectoires issues de données GNSS constituent des séries d'observations spatiales et temporelles qui ne sont généralement pas directement exploitables pour une analyse quantitative. Elles peuvent contenir des observations aberrantes, des irrégularités temporelles, des interruptions d'enregistrement ou encore un nombre de points variable selon les déplacements. Un prétraitement est donc nécessaire afin d'obtenir des trajectoires cohérentes tout en conservant les caractéristiques essentielles du déplacement.

2.2.1 Prétraitement des trajectoires

Le prétraitement d'une trajectoire peut comprendre plusieurs opérations successives. La première consiste à vérifier la validité des observations spatiales et temporelles. Les intervalles de temps entre deux observations successives peuvent ensuite être utilisés pour calculer des grandeurs cinématiques, notamment la vitesse.

Ces informations peuvent être utilisées pour détecter des observations incompatibles avec le mode de déplacement étudié. Dans le cas de trajectoires piétonnes, des valeurs de vitesse anormalement élevées peuvent, par exemple, révéler des erreurs de positionnement ou des changements de mode de transport.

Le prétraitement permet également de définir des critères minimaux de qualité pour les trajectoires. Le nombre d'observations, la durée, la continuité temporelle ou encore la vitesse peuvent ainsi être utilisés pour sélectionner les déplacements suffisamment complets et cohérents pour les analyses ultérieures.

2.2.2 Simplification géométrique des trajectoires

Les trajectoires peuvent contenir un nombre important de points, notamment lorsque la fréquence d'acquisition est élevée. Une simplification géométrique permet de réduire le nombre de points tout en conservant une approximation satisfaisante de la forme générale de la trajectoire.

L'algorithme de Douglas-Peucker[20] constitue une méthode classique de simplification de lignes. Il repose sur une approche récursive consistant à comparer les points intermédiaires d'une ligne au segment reliant ses extrémités. Le point présentant la distance maximale à ce segment est conservé si cette distance dépasse un seuil prédéfini. La procédure est ensuite appliquée récursivement aux sous-segments obtenus.




FIGURE 1 – Application de Douglas-Peucker sur une trace.

Soit une trajectoire constituée d'une séquence de points $P_1, \dots, P_n$. Pour un segment reliant les points extrêmes P_1 et P_n , on recherche le point P_i maximisant sa distance au segment :

$$d_{\max} = \max_i d(P_i, \overline{P_1 P_n}). \quad (2)$$

Si $d_{\max}$ est inférieur au seuil de tolérance ϵ , les points intermédiaires peuvent être supprimés. Dans le cas contraire, le point correspondant est conservé et la procédure est appliquée récursivement aux deux sous-trajectoires.

Le choix de ϵ constitue un compromis entre la réduction du nombre de points et la conservation de la géométrie de la trajectoire. Une tolérance trop faible produit une simplification limitée, tandis qu'une tolérance trop importante peut supprimer des variations spatiales significatives.

2.2.3 Descripteurs des trajectoires

Une fois les trajectoires nettoyées et structurées, différentes caractéristiques peuvent être calculées afin de décrire les déplacements. Parmi les descripteurs

couramment utilisés figurent notamment la longueur de la trajectoire, sa durée, le nombre d'observations, la vitesse moyenne.

La longueur d'une trajectoire composée de n observations peut être estimée par la somme des distances entre positions successives :

$$L(T) = \sum_{i=1}^{n-1} d(P_i, P_{i+1}). \quad (3)$$

La durée totale est donnée par :

$$D(T) = t_n - t_1. \quad (4)$$

Ces descripteurs permettent de réaliser une première analyse exploratoire des données et de comparer les caractéristiques générales des déplacements. Ils peuvent également être utilisés pour détecter des trajectoires atypiques ou pour construire des groupes de trajectoires présentant des propriétés similaires.

2.2.4 Détermination des traces de jour et nocturnes

La distinction entre les déplacements de jour et de nuit est définie à partir du crépuscule nautique, plutôt qu'à partir d'horaires fixes. Celui-ci correspond à la période durant laquelle le centre du Soleil se situe entre 6° et 12° sous l'horizon.

Pour chaque observation, les limites de la période nocturne sont calculées à partir de sa date et de sa localisation. Une observation est ainsi classée comme appartenant au jour ou à la nuit selon sa position par rapport à ces limites.

Cette définition prend en compte les variations saisonnières et géographiques de la luminosité naturelle et permet d'appliquer la même règle à l'ensemble des trajectoires.

2.3 Regroupement et comparaison des trajectoires

L'analyse d'un ensemble de trajectoires ne consiste pas uniquement à étudier chaque déplacement individuellement. Lorsque le nombre de trajectoires devient important, il peut être pertinent d'identifier des groupes de déplacements présentant des caractéristiques communes. Cette approche permet notamment d'explorer la structure de la mobilité, de distinguer différents types de déplacements et de rechercher des comportements similaires.

Deux dimensions complémentaires peuvent être considérées pour comparer des trajectoires. La première repose sur leurs caractéristiques globales, telles que les points de départ et d'arrivée, la longueur ou la durée du déplacement.

La seconde porte directement sur leur géométrie et leur évolution spatiale. Ces deux approches ont été explorées dans le cadre du projet.

2.3.1 Principe du clustering

Le *clustering*, ou classification non supervisée, consiste à partitionner un ensemble d'observations en groupes homogènes selon une mesure de similarité ou de distance. Contrairement à une classification supervisée, les groupes ne sont pas définis à partir d'étiquettes connues a priori. Ils sont construits à partir des propriétés intrinsèques des données.

De nombreuses méthodes de clustering existent, avec des principes différents. Les méthodes de partitionnement, telles que *k-means*, cherchent à construire un nombre fixé de groupes en minimisant une fonction de dispersion intra-classe. Les méthodes hiérarchiques construisent quant à elles une organisation des observations sous la forme d'un dendrogramme, permettant d'étudier différents niveaux de regroupement. D'autres méthodes, telles que DBSCAN, définissent les groupes à partir de la densité spatiale des observations et permettent notamment d'identifier des observations atypiques.

L'application d'un algorithme de clustering nécessite cependant de définir une représentation des trajectoires ainsi qu'une mesure permettant de comparer les observations. Ce choix est particulièrement important dans le cas des trajectoires, car deux déplacements peuvent être similaires sans contenir le même nombre de points ni avoir été échantillonnés aux mêmes instants.

2.3.2 Regroupement selon les couples origine–destination

Une première approche consiste à considérer les couples origine–destination (OD) des déplacements. Chaque trajectoire est alors représentée par son point de départ et son point d'arrivée, et les trajectoires correspondant à des zones de départ et d'arrivée proches peuvent être regroupées.

Cette représentation permet de réduire la complexité du jeu de données et d'identifier les principaux flux de déplacement. Elle présente également l'avantage de ne pas nécessiter de comparer directement l'ensemble des points composant les trajectoires.

Cependant, deux trajectoires ayant des origines et destinations similaires peuvent emprunter des itinéraires très différents. Le regroupement par couples OD décrit donc davantage la structure des flux que la similarité géométrique des itinéraires. À l'inverse, des trajectoires ayant des formes très proches mais des extrémités légèrement différentes peuvent être considérées comme appartenant à des groupes distincts.

Cette distinction est importante dans le cadre de l'étude, car l'objectif n'est

pas uniquement d'identifier les principaux flux de mobilité, mais également de déterminer si des trajectoires présentant des caractéristiques spatiales similaires peuvent être mises en relation avec leur environnement urbain.

2.3.3 Comparaison géométrique des trajectoires

Pour comparer directement deux trajectoires, il est nécessaire de définir une mesure de distance ou de similarité adaptée à des séquences de positions.

Soient deux trajectoires :

$$T^{(1)} = (P_1, \dots, P_n) \quad (5)$$

et

$$T^{(2)} = (Q_1, \dots, Q_m), \quad (6)$$

où les deux trajectoires peuvent avoir des nombres de points différents, $n \neq m$.

Une comparaison point à point classique est difficile dans ce cas, car il n'existe pas nécessairement de correspondance directe entre les observations des deux trajectoires. Cette difficulté est particulièrement importante lorsque les trajectoires ont été enregistrées avec des fréquences différentes ou lorsque les vitesses de déplacement diffèrent.

Une des mesures de similarité existantes est la *Dynamic Time Warping*, qui permet d'établir une correspondance flexible entre les points de deux trajectoires.

2.3.4 Dynamic Time Warping

La *Dynamic Time Warping* (DTW)[15] est une méthode de comparaison de séquences permettant de mesurer leur similarité malgré des différences dans leur rythme d'évolution. Initialement utilisée pour la comparaison de signaux temporels, elle peut être appliquée aux trajectoires en considérant les positions successives comme les éléments des séquences à comparer.

Soient deux trajectoires $T^{(1)}$ et $T^{(2)}$ comportant respectivement n et m observations. On définit d'abord une matrice de coûts locale :

$$C(i, j) = d(P_i, Q_j), \quad (7)$$

où d représente une distance entre les deux positions, par exemple la distance euclidienne dans un système de coordonnées projetées.

La DTW recherche ensuite un chemin optimal dans cette matrice afin d'établir une correspondance entre les deux séquences. La distance cumulée peut

être calculée récursivement selon :

$$D(i, j) = C(i, j) + \min D(i - 1, j), D(i, j - 1), D(i - 1, j - 1) \quad , \quad (8)$$

avec les conditions initiales appropriées.

Le chemin obtenu permet ainsi de mettre en correspondance plusieurs observations d'une trajectoire avec une ou plusieurs observations de l'autre. Cette propriété permet notamment de comparer des trajectoires dont les fréquences d'échantillonnage ou les vitesses de déplacement sont différentes.

La DTW présente néanmoins certaines limites lorsqu'elle est appliquée directement à des trajectoires géographiques. La mesure obtenue dépend de la représentation des trajectoires et de la distance utilisée entre les positions. De plus, une similarité géométrique importante ne signifie pas nécessairement que deux trajectoires suivent le même réseau viaire. Deux trajectoires peuvent par exemple être proches dans l'espace tout en se situant sur des infrastructures différentes.

Par ailleurs, le calcul de la DTW peut devenir coûteux lorsque le nombre de trajectoires et leur longueur augmentent. Une comparaison exhaustive de toutes les paires de trajectoires présente ainsi une complexité qui peut devenir importante pour de grands jeux de données.

2.3.5 Approches explorées dans le projet

Dans le cadre de ce travail, plusieurs approches ont été considérées afin d'explorer la structure des trajectoires avant de procéder à leur analyse environnementale.

Une première approche a consisté à étudier les déplacements à partir de leurs couples origine–destination. Cette représentation permet d'identifier les principaux types de flux et de vérifier si certaines trajectoires pouvaient être regroupées selon leurs zones de départ et d'arrivée.

Une seconde approche repose sur la comparaison directe de la géométrie des trajectoires. Des mesures de similarité entre trajectoires, notamment fondées sur la DTW, ont été étudiées afin de déterminer si des groupes de déplacements présentant des formes spatiales similaires peuvent être identifiés.

Ces méthodes de clustering ont été explorées comme une piste d'analyse des trajectoires, sans constituer une étape complète du pipeline final. Les résultats obtenus et les limites rencontrées sont présentés en annexe.

2.4 Map matching

Les trajectoires GPS représentent les déplacements sous la forme d'une succession de positions, mais ces positions ne correspondent pas nécessairement exactement aux infrastructures réellement empruntées. Le *map matching*[3], ou recalage cartographique, consiste à associer les observations d'une trajectoire aux éléments d'un réseau de transport afin de reconstruire l'itinéraire suivi.

Cette étape est particulièrement importante pour les déplacements piétons, pour lesquels les erreurs de positionnement peuvent être du même ordre de grandeur que la largeur d'une rue ou d'un chemin. Le recalage permet ainsi de passer d'une représentation fondée sur des coordonnées à une représentation fondée sur le graphe piéton.

2.4.1 Approches géométriques par projection

Une approche simple consiste à rechercher, pour chaque position, le segment du graphe le plus proche et à projeter la position sur celui-ci. Cette méthode est relativement simple à mettre en œuvre et permet d'obtenir rapidement une correspondance entre les observations et le réseau.

Cependant, les observations sont généralement traitées indépendamment les unes des autres. Dans une intersection ou dans une zone où plusieurs rues sont proches, une succession de projections indépendantes peut conduire à des changements de rue incohérents. Cette approche ne tient pas non plus directement compte de la continuité de l'itinéraire.

Des méthodes plus élaborées cherchent donc à déterminer une séquence cohérente de positions sur le réseau plutôt qu'à traiter chaque observation séparément.

2.4.2 Map matching par modèle de Markov caché

Les modèles de Markov cachés (*Hidden Markov Models*, HMM)[3] permettent de formuler le problème de *map matching* comme une recherche de la séquence d'états du réseau la plus probable étant donné une séquence d'observations GPS. Cette approche permet de prendre simultanément en compte l'incertitude de localisation et la structure du graphe [3].

Soit une trajectoire composée de n observations :

$$O = (o_1, o_2, \dots, o_n), \quad (9)$$

où o_i représente la position observée à l'instant t_i .

Le modèle considère que ces observations sont générées par une séquence d'états cachés :

$$S = (s_1, s_2, \dots, s_n), \quad (10)$$

où chaque état s_i correspond à une position ou à un élément du réseau susceptible de représenter la position réelle du piéton.

Le terme « caché » signifie que l'itinéraire réellement emprunté n'est pas directement observé. Seules les positions bruitées sont disponibles. Le rôle du modèle est donc d'inférer la séquence de segments du réseau la plus vraisemblable à partir de ces observations.

Génération des états candidats.

Pour chaque observation o_i , plusieurs éléments du réseau peuvent être considérés comme candidats. Les candidats sont généralement recherchés dans un voisinage spatial de l'observation. Une observation située à proximité de plusieurs rues peut donc être associée à plusieurs états possibles.

Probabilité d'émission.

La probabilité d'émission mesure la compatibilité entre une observation et un état du graphe. Elle traduit notamment l'incertitude du positionnement GPS : plus la distance entre l'observation et sa position candidate sur le réseau est importante, moins cette association est probable.

Une formulation classique consiste à utiliser une distribution gaussienne de l'erreur de localisation.

On peut ainsi représenter de manière simplifiée cette relation par :

$$P(o_i | s_i) \propto \exp \left(-\frac{d(o_i, s_i)^2}{2\sigma_o^2} \right), \quad (11)$$

où $d(o_i, s_i)$ représente la distance entre l'observation et l'état candidat et σ_o caractérise le niveau de bruit associé aux observations.

Probabilité de transition.

La seule proximité des observations avec le réseau n'est toutefois pas suffisante. Il faut également vérifier que le passage d'un état s_{i-1} à un état s_i est cohérent avec le déplacement observé.

La probabilité de transition mesure ainsi la compatibilité entre deux états successifs. Elle peut notamment prendre en compte :

- la connectivité des segments du réseau ;

- la distance parcourue sur le réseau entre deux observations ;
- la distance géométrique entre les observations GPS ;
- les changements de direction ou les retours vers des segments précédemment parcourus.

Dans *DistanceMatcher*, la différence entre la distance parcourue entre deux positions GPS et celle correspondant aux positions candidates sur le réseau intervient notamment dans cette probabilité. Les transitions vers des segments non connectés ou correspondant à un retour en arrière sont également pénalisées.

On peut schématiquement écrire :

$$P(s_i \mid s_{i-1}) \propto \exp \left(-\frac{d_t^2}{2\sigma_d^2} \right), \quad (12)$$

où d_t représente l'écart entre la distance observée et la distance correspondante sur le réseau, et σ_d contrôle la tolérance associée à cette différence.

Le modèle cherche ainsi un compromis entre deux contraintes : les états sélectionnés doivent être suffisamment proches des observations GPS, tout en formant un chemin cohérent sur le réseau.

Recherche de la séquence optimale.

La séquence d'états la plus probable est recherchée à l'aide de l'algorithme de Viterbi :

$$S^* = \arg \max_S P(S \mid O). \quad (13)$$

L'algorithme évalue progressivement les états candidats et conserve, pour chacun, la meilleure séquence obtenue à partir des observations précédentes. La recherche peut être représentée sous forme de *lattice*, chaque niveau correspondant à une observation.

États non émissifs.

Entre deux observations GPS, le trajet peut emprunter plusieurs segments du réseau sans qu'une observation ne corresponde directement à chacun d'eux. Les états non émissifs permettent de représenter ces segments intermédiaires et de construire un chemin continu entre les observations.

Cette possibilité est utilisée par la bibliothèque *Leuven Map Matching*[4] et permet notamment de gérer les trajectoires dont les observations sont espacées ou irrégulières.

2.4.3 Méthode utilisée dans le projet

Dans ce travail, le recalage a été réalisé avec la bibliothèque *Leuven Map Matching*[4], qui implémente une approche HMM avec états non émissifs[3]. Le réseau utilisé correspond au graphe piéton extrait d'OpenStreetMap.

La méthode *DistanceMatcher* a été retenue. Elle prend en compte non seulement la proximité entre les observations GPS et le réseau, mais également la cohérence des distances parcourues entre deux observations successives.

Le détail de la construction du réseau, de la génération des candidats, des paramètres utilisés pour contrôler les distances et les niveaux de bruit, ainsi que les critères permettant d'évaluer la qualité du recalage sont présentés dans la partie 6.

2.5 Caractérisation de l'environnement urbain

L'analyse des déterminants environnementaux de la mobilité piétonne nécessite de transformer les éléments physiques de l'espace urbain en variables quantitatives. Dans le cadre de cette étude, plusieurs dimensions de l'environnement sont considérées : le bâti, sa hauteur, l'éclairage public et les propriétés de visibilité de l'espace.

Ces informations permettent de décrire l'environnement rencontré par un piéton à différents points de sa trajectoire et peuvent ensuite être mises en relation avec les caractéristiques des déplacements.

2.5.1 Représentation du bâti

Les bâtiments constituent une composante majeure de la structure urbaine. Leur emprise au sol permet notamment de représenter les obstacles physiques qui délimitent les espaces de circulation et influencent la visibilité depuis une trajectoire.[14]

Les données de bâtiments peuvent être représentées sous forme de géométries polygonales auxquelles sont associées différentes propriétés, notamment leur hauteur. Cette information permet de passer d'une représentation bidimensionnelle du bâti à une représentation simplifiée de sa volumétrie.

La hauteur des bâtiments peut notamment être utilisée pour caractériser la morphologie des rues et pour calculer des indicateurs de visibilité. Elle intervient en particulier dans les méthodes fondées sur la géométrie tridimensionnelle de l'environnement.

2.5.2 Hauteur et morphologie urbaine

La géométrie du bâti influence directement la configuration spatiale des rues. Des bâtiments élevés et rapprochés peuvent par exemple produire un espace plus fortement enclavé, tandis qu'un environnement plus ouvert offre une visibilité potentiellement plus importante vers le ciel et les espaces environnants.

Différents indicateurs géométriques peuvent être utilisés pour caractériser cette relation entre hauteur du bâti et largeur des espaces urbains. Ces indicateurs permettent de quantifier des propriétés qui seraient difficiles à représenter à partir de la seule géométrie bidimensionnelle.

2.5.3 Éclairage public

L'éclairage public constitue une autre composante importante de l'environnement nocturne. Sa représentation peut être obtenue à partir de données géolocalisées décrivant la position des dispositifs d'éclairage.

La proximité d'un point de trajectoire avec les équipements d'éclairage peut ainsi être utilisée comme indicateur simple de la présence potentielle d'un éclairage public. D'autres caractéristiques pourraient également être considérées lorsque les données disponibles le permettent, telles que la densité des équipements ou leur répartition le long du réseau.

Dans le cadre de cette étude, les données d'éclairage sont principalement utilisées comme une information environnementale complémentaire aux caractéristiques morphologiques du bâti.

2.5.4 Visibilité et isovistes

La visibilité constitue une dimension particulière de l'environnement urbain, car elle permet de caractériser ce qu'un piéton peut potentiellement percevoir depuis une position donnée.

L'isoviste[18] représente l'espace visible depuis un point d'observation en tenant compte des obstacles environnants. Il permet d'en extraire différentes mesures, telles que la surface, le périmètre ou la distribution des distances de visibilité, utilisées comme variables quantitatives pour caractériser l'environnement des trajectoires.

2.5.5 Sky View Factor

Le *Sky View Factor* (SVF) est un indicateur permettant de quantifier la proportion du ciel visible depuis un point donné. Il est exprimé entre 0 et 1 : une valeur proche de 1 correspond à un environnement largement ouvert vers le

ciel, tandis qu'une valeur faible indique un environnement davantage masqué par les obstacles environnants. Il permet de caractériser le degré d'ouverture d'un espace par rapport au ciel.

Pour une trajectoire piétonne, le calcul du SVF peut être réalisé à chaque position ou sur un ensemble de points échantillonnés. On obtient alors une série de valeurs décrivant l'évolution de l'ouverture spatiale le long du déplacement.

Le SVF ne décrit cependant qu'une dimension particulière de la visibilité. Deux environnements peuvent présenter un SVF similaire tout en ayant des configurations spatiales différentes. Il est donc pertinent de le compléter par d'autres indicateurs issus des rayons de visibilité et des isovistes.

2.5.6 Indicateurs morphologiques issus des rayons de visibilité

Les longueurs des rayons de visibilité permettent de construire différents descripteurs de la morphologie locale. Pour un ensemble de rayons de longueurs $r_1, \dots, r_k$, on peut notamment calculer leur minimum, leur moyenne et leur médiane ainsi que différents indicateurs décrivant la dispersion ou la distribution des longueurs.

Ces mesures permettent de distinguer plusieurs configurations spatiales. Un environnement dans lequel les rayons sont généralement longs correspond à un espace relativement ouvert, tandis que des rayons courts traduisent la présence d'obstacles proches. La distribution des longueurs dans différentes directions permet également de caractériser des environnements dont la visibilité est fortement anisotrope, par exemple lorsque la vue est dégagée dans l'axe d'une rue mais limitée perpendiculairement.

Dans le projet, ces indicateurs sont calculés conjointement au SVF afin d'obtenir une description plus complète de l'environnement morphologique autour des trajectoires. Leur utilisation permet ainsi de compléter les informations directement issues des bâtiments par des variables décrivant l'espace effectivement visible depuis le point de déplacement.

3 Données et zones d'étude

L'étude repose sur plusieurs sources de données permettant de mettre en relation les trajectoires piétonnes avec les caractéristiques de leur environnement urbain. Les données de localisation constituent la donnée principale du projet. Elles sont complétées par des données décrivant le réseau piéton, le bâti, la hauteur des bâtiments et l'éclairage public.

Trois zones d'étude ont été considérées au cours du projet : **Paris**, **Londres** et **Pékin**. Ces trois territoires permettent de travailler avec des sources de données différentes et de tester la reproductibilité de la chaîne de traitement dans des contextes urbains distincts.

Les données disponibles ne présentent cependant pas les mêmes caractéristiques selon les villes. Les trajectoires de Paris et Londres sont principalement issues de traces GPS au format GPX, tandis que les trajectoires utilisées pour Pékin proviennent du jeu de données GeoLife. De même, les données décrivant le bâti ne proviennent pas d'une source unique : la BD TOPO® de l'IGN est utilisée pour Paris, tandis que le GlobalBuildingAtlas est utilisé pour Londres.

Cette diversité constitue à la fois une contrainte et un intérêt méthodologique. Elle nécessite une phase d'harmonisation des données, mais permet également d'évaluer la capacité du pipeline développé à traiter des sources hétérogènes.

3.1 Zones d'étude

3.1.1 Paris

Paris constitue la première zone d'étude du projet. La ville présente un tissu urbain dense et continu, caractérisé par une forte concentration du bâti et par un réseau piéton particulièrement développé.

Paris constitue également le principal terrain de développement et de validation du pipeline. Les différentes étapes de traitement des trajectoires, de construction du réseau piéton et de caractérisation de l'environnement urbain ont d'abord été mises en œuvre sur cette zone avant d'être adaptées aux autres villes.




FIGURE 2 – extrait de traces piéton à Paris.

3.1.2 Londres

Londres constitue la deuxième zone d'étude. Elle permet notamment d'évaluer la capacité du pipeline à fonctionner sur un réseau urbain de grande taille et sur un volume de trajectoires sensiblement supérieur à celui disponible pour Paris.

3.1.3 Pékin

Pékin constitue la troisième zone d'étude et présente une configuration différente des deux précédentes. Les trajectoires utilisées proviennent du dataset *GeoLife*, développé par Microsoft Research.

L'intérêt principal de cette zone d'étude réside dans la nature des données disponibles. Contrairement aux traces GPX utilisées pour Paris et Londres, *GeoLife* fournit des informations complémentaires sur les utilisateurs et, pour une partie d'entre eux, sur le mode de transport utilisé.

Cette source permet ainsi de disposer d'un ensemble de trajectoires piétonnes indépendant des données utilisées pour les deux autres villes et d'évaluer la reproductibilité du traitement sur un jeu de données construit selon un protocole différent.




FIGURE 3 – Extrait de traces piéton à Pékin.

3.2 Sources de données

L'étude mobilise plusieurs sources de données complémentaires. Elles peuvent être regroupées en trois catégories principales : les données de trajectoires, les données du réseau urbain et les données décrivant l'environnement bâti et lumineux.

TABLE 1 – Principales sources de données utilisées dans le projet.

Source	Type	Zone	Utilisation
OSM	Données géographiques	3 zones	graphe piéton
OSM	Trajectoires GPS	Paris, Londres	Mobilité piétonne
BD TOPO [®]	Données géographiques	Paris	Bâti et hauteur
GlobalBuildingAtlas	Données 3D	Londres, Pékin	Bâti et hauteur
Éclairage public	Données ponctuelles	Paris	Éclairage artificiel
GeoLife	Trajectoires GPS	Pékin	Mobilité piétonne

3.2.1 OpenStreetMap

OpenStreetMap (OSM) est une base de données géographiques collaborative contenant des informations sur de nombreux objets géographiques. Elle décrit notamment les routes, chemins, sentiers et autres infrastructures de déplacement.

Dans le cadre de ce projet, OSM est principalement utilisé pour l'extraction des traces et construire le graphe piéton des villes. Les éléments compatibles avec les déplacements à pied sont extraits puis transformés en graphe afin de représenter les possibilités de déplacement sur le réseau urbain.

Ce graphe constitue une donnée essentielle pour l'étape de *map matching*. Il permet de rechercher, pour chaque trajectoire GPS, la séquence d'éléments du réseau la plus cohérente avec les observations. L'utilisation d'OpenStreetMap permet ainsi de disposer d'une représentation détaillée du réseau piéton tout en conservant une méthodologie reproductible pouvant être appliquée à d'autres villes.

3.2.2 Données GPX

```
<?xml version="1.0" encoding="UTF-8"?>
<gpx version="1.1" creator="JOSM GPX export" xmlns="http://www.topografix.com/GPX/1/1"
  xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
  xsi:schemaLocation="http://www.topografix.com/GPX/1/1 http://www.topografix.com/GPX/1/1/gpx.xsd http://josm.openstreetmap.de/gpx-extensions-1.1
  http://josm.openstreetmap.de/gpx-extensions-1.1.xsd">
  <metadata>
    <time>2026-04-21T08:43:37.940118800Z</time>
    <bounds minlat="48.823593" minlon="2.27005" maxlat="48.903089" maxlon="2.403945"/>
    <extensions>
      <josm:from-server>true</josm:from-server>
    </extensions>
  </metadata>
  <trk>
    <trkseg>
      <trkpt lat="48.85725" lon="2.347425">
        <time>2005-11-07T12:03:31Z</time>
      </trkpt>
      <trkpt lat="48.857673" lon="2.34775">
        <time>2005-11-07T12:03:31Z</time>
      </trkpt>
      <trkpt lat="48.857191" lon="2.347177">
        <time>2005-11-07T12:03:31Z</time>
      </trkpt>
      <trkpt lat="48.857154" lon="2.347054">
        <time>2005-11-07T12:03:31Z</time>
      </trkpt>
      <trkpt lat="48.857037" lon="2.346988">
        <time>2005-11-07T12:03:31Z</time>
      </trkpt>
      <trkpt lat="48.856712" lon="2.346801">
        <time>2005-11-07T12:03:31Z</time>
      </trkpt>
    </trkseg>
  </trk>
</gpx>
```

FIGURE 4 – fichier GPX.

Les trajectoires utilisées pour Paris et Londres sont disponibles sous forme de fichiers GPX (*GPS Exchange Format*). Le format GPX est un format XML permettant notamment de stocker des points de localisation associés à des informations temporelles.

Chaque observation peut ainsi être représentée par ses coordonnées géographiques et, lorsqu'elle est disponible, par son horodatage. La succession de ces observations permet de reconstruire une trajectoire.

Les données GPX présentent cependant une certaine hétérogénéité. Les fichiers peuvent différer dans leur structure, leur organisation et la présence ou non d'informations temporelles. Dans certaines situations, plusieurs traces peuvent également être regroupées dans un même fichier ou présenter des interruptions d'enregistrement.

Une chaîne de traitement spécifique est donc nécessaire afin de transformer les fichiers bruts en trajectoires individuelles exploitables.

3.2.3 BD TOPO®

Pour Paris, les données relatives au bâti sont issues de la BD TOPO® de l'Institut national de l'information géographique et forestière (IGN).

La BD TOPO® fournit des données géographiques décrivant notamment les bâtiments et différentes informations associées à leur géométrie. Dans cette étude, la hauteur des bâtiments constitue une information particulièrement importante.

La couche préparée pour l'étude contient **606,632 bâtiments**. Parmi ceux-ci, **531,534** disposent d'une valeur de hauteur valide. La hauteur moyenne des

bâtiments valides est de **9,67 m**, tandis que la valeur maximale observée est de **286,4 m**.

Ces informations sont utilisées pour caractériser la morphologie du bâti autour des trajectoires et pour calculer différents indicateurs de visibilité et de configuration spatiale.

3.2.4 GlobalBuildingAtlas

Le **GlobalBuildingAtlas (GBA)**[5] est une base de données mondiale décrivant les bâtiments à partir de leur emprise au sol et de leur hauteur. Ces informations permettent de représenter le bâti sous forme de volumes et de caractériser la morphologie de l'environnement urbain.

Dans ce travail, une représentation de type **Level of Detail 1 (LoD1)** est utilisée. Les bâtiments sont représentés sous forme de volumes extrudés à partir de leur emprise au sol, avec une hauteur associée à chaque bâtiment.

La préparation des données consiste à identifier et télécharger les tuiles couvrant la zone d'étude, puis à les reprojeter et à les découper selon l'emprise considérée. Un script a été développé afin d'automatiser cette récupération et de rendre le traitement réutilisable pour différentes zones d'étude.

L'utilisation du GlobalBuildingAtlas pour Londres et de la BD TOPO® pour Paris constitue un exemple de l'hétérogénéité des sources disponibles selon les territoires. Les deux jeux de données doivent donc être préparés de manière à fournir des informations comparables pour les analyses environnementales.

3.2.5 Données d'éclairage public

L'éclairage artificiel constitue une dimension importante de l'environnement urbain nocturne. Pour Paris, les données d'éclairage public utilisées dans le projet fournissent la localisation des équipements d'éclairage.

Après préparation, le jeu de données utilisé comprend **165,594 points d'éclairage**. Chaque équipement est représenté par une position géographique permettant d'étudier sa proximité avec les trajectoires et le réseau piéton.

Ces données permettent notamment de construire des indicateurs décrivant la présence et la densité de l'éclairage public dans l'environnement traversé par les piétons.

3.2.6 GeoLife

Le jeu de données *GeoLife*[16], développé par Microsoft Research, constitue la principale source de trajectoires utilisée pour Pékin.

Le dataset contient les trajectoires GPS de **182 utilisateurs**. Les données ont été collectées sur une longue période et présentent une fréquence d'acquisition

variable, comprise approximativement entre **1 seconde et 1 minute** selon les enregistrements.

Une partie des trajectoires est également associée à des informations sur le mode de transport. Parmi les 182 utilisateurs, **73 disposent d'un label de transport**, dont **60 ont un label correspondant à la marche**.

Après sélection et prétraitement, le jeu utilisé dans cette étude comprend **2,184 trajectoires piétonnes**, représentant environ **1,4 million de points GPS**. Parmi ces trajectoires, **516 sont classées comme nocturnes**, soit environ **23, %**.

Cette source présente ainsi l'avantage de fournir des informations complémentaires sur les déplacements, tout en introduisant une fréquence d'échantillonnage plus variable que celle des traces GPX utilisées pour Paris et Londres.

3.2.7 Outdoorvision

Une source complémentaire, *Outdoorvision*, avait été envisagée au cours du projet afin de disposer de données supplémentaires de mobilité. Une demande d'accès a été effectuée, mais les données n'ont pas été reçues pendant la durée du stage.

Cette source n'a donc pas été intégrée aux analyses. Les travaux présentés dans ce rapport reposent uniquement sur les données effectivement disponibles et traitées au cours du stage.

3.3 Données de trajectoires

Les trajectoires constituent la donnée centrale de cette étude. Elles permettent de décrire les déplacements réellement observés et servent de support aux étapes ultérieures de classification temporelle, de *map matching* et de caractérisation de l'environnement urbain.

Les trois sources utilisées présentent cependant des caractéristiques différentes. Les données de Paris et Londres sont constituées de traces GPX présentant un pas temporel d'environ une seconde après préparation, tandis que les trajectoires GeoLife conservent une fréquence d'acquisition variable.

3.3.1 Extraction et reconstruction

Pour les données GPX, le processus commence par le **parsing des fichiers XML**. Les informations disponibles dans chaque fichier sont parcourues afin d'extraire les observations GPS.

Pour chaque point, les principales informations recherchées sont :

- la latitude ;

- la longitude ;
- l'horodatage ;
- l'identifiant permettant de rattacher le point à une trajectoire lorsque celui-ci est disponible.

Une sélection spatiale est ensuite effectuée à partir d'une *bounding box* définissant la zone d'étude. Les observations situées dans la zone considérée sont conservées, puis regroupées afin de reconstruire les trajectoires individuelles.

La chaîne d'extraction peut ainsi être résumée par :

1. lecture et parsing des fichiers GPX ;
2. extraction des coordonnées et des informations temporelles ;
3. sélection des points appartenant à la zone d'étude ;
4. reconstruction des trajectoires ;
5. contrôle de la cohérence spatiale et temporelle ;
6. filtrage des trajectoires ;
7. classification jour/nuit.

Le même principe général est appliqué aux données GeoLife, en tenant compte de la structure spécifique du dataset.

3.3.2 Statistiques des trajectoires

Après les opérations de sélection et de filtrage, les données disponibles présentent des volumes différents selon les villes.

TABLE 2 – Statistiques des trajectoires utilisées dans l'étude.

Ville	Source	Traces	Points GPS	Nuit
Paris	OSM	893	> 540 000	80 (9 %)
Londres	OSM	8 431	> 4,1 M	429 (5 %)
Pékin	GeoLife	2 184	~ 1,4 M	516 (23 %)

Pour Paris, le jeu de données final comprend **893 trajectoires**, représentant plus de **540,000 points GPS**. Les trajectoires utilisées présentent un pas temporel d'environ **1 seconde**. Parmi elles, **80 trajectoires**, soit environ **9%**, sont classées comme nocturnes.

Le jeu londonien est sensiblement plus important. Il comprend **8,431 trajectoires** et plus de **4,1 millions de points GPS**, également avec un pas temporel d'environ **1 seconde**. Parmi ces trajectoires, **429**, soit environ **5, %**, sont classées comme nocturnes.

Enfin, le jeu GeoLife utilisé pour Pékin comprend **2,184 trajectoires piétonnes** et environ **1,4 million de points GPS**. Parmi ces trajectoires, **516**, soit environ **23, %**, sont classées comme nocturnes.

Ces chiffres montrent que les jeux de données sont fortement déséquilibrés en termes de volume et de proportion de déplacements nocturnes. Le jeu londonien est notamment beaucoup plus volumineux que celui de Paris, tandis que GeoLife présente une proportion de trajectoires nocturnes plus importante.

3.4 Difficultés liées aux données

La constitution d'un jeu de trajectoires homogène à partir de sources hétérogènes a fait apparaître plusieurs difficultés.

La première concerne le bruit des observations GPS. Les positions enregistrées ne correspondent pas nécessairement exactement à la position réelle du piéton. Des points aberrants peuvent notamment apparaître et produire artificiellement des vitesses élevées ou des déplacements incohérents.

La deuxième difficulté concerne les trajectoires incomplètes ou très courtes. Certaines séquences contiennent trop peu d'observations pour permettre une analyse fiable du déplacement ou un recalage satisfaisant sur le réseau. Elles doivent donc être éliminées au cours du filtrage.

Les données GPX présentent également une hétérogénéité de structure. Les fichiers peuvent différer dans leur organisation XML, leurs informations disponibles ou leur manière de représenter les segments de trajectoire. Certains fichiers peuvent également ne pas contenir d'horodatage exploitable.

Une autre difficulté est l'absence de labels homogènes. Les données GPS ne permettent pas toujours de savoir directement si une trajectoire correspond à un déplacement à pied ou à un autre mode de transport. De même, la distinction entre jour et nuit n'est pas fournie directement dans les traces GPX et doit être déterminée à partir des informations temporelles et d'une définition astronomique.

Le volume des données constitue également une contrainte. Les différences sont importantes entre les villes, avec plus de 4,1 millions de points pour Londres contre plus de 540,000 pour Paris. L'utilisation de traitements spatiaux sur plusieurs millions d'observations nécessite donc une organisation adaptée des données et des traitements.

Enfin, l'extraction des données géographiques peut elle-même représenter une contrainte technique. Certaines opérations d'interrogation des données OSM via des interfaces ou API peuvent devenir très lentes lorsque la zone d'étude ou le volume demandé augmente. Le téléchargement, le stockage local et la préparation préalable des données se sont donc révélés nécessaires pour certaines étapes du projet.

Ces différentes difficultés justifient la mise en place d'un pipeline de pré-traitement commun permettant de normaliser autant que possible les données avant les analyses.

3.5 Harmonisation des données

Les différentes sources ne sont pas directement comparables dans leur format initial. Une étape d'harmonisation est donc nécessaire afin de pouvoir appliquer des méthodes communes aux différentes zones d'étude.

Cette harmonisation porte notamment sur les aspects suivants :

- la structure des trajectoires et l'identification des observations ;
- les systèmes de coordonnées utilisés ;
- la représentation temporelle des observations ;
- les critères de sélection des déplacements piétonniers ;
- la classification des trajectoires selon leur caractère diurne ou nocturne ;
- la représentation du réseau piéton ;
- les formats des données décrivant le bâti et les autres éléments de l'environnement urbain.

Pour les données spatiales, les différentes couches utilisées doivent notamment être reprojeter dans des systèmes de coordonnées adaptés aux calculs géométriques réalisés dans chaque zone d'étude. Pour Paris, les données finales utilisées pour les traitements spatiaux sont notamment exprimées dans le système **EPSG :2154**.

La préparation des trajectoires et les critères de filtrage utilisés pour obtenir les jeux de données présentés dans ce chapitre sont détaillés dans les chapitres suivants.

4 Exploration et analyse préliminaire des trajectoires

Avant de procéder au recalage des trajectoires sur le réseau piéton et à l'extraction des caractéristiques de l'environnement urbain, une phase d'analyse exploratoire a été réalisée sur les données disponibles. Cette étape vise à mieux comprendre la structure des trajectoires, à identifier les principales sources de variabilité entre les jeux de données et à détecter d'éventuelles anomalies susceptibles d'affecter les traitements ultérieurs.

L'analyse exploratoire constitue également une étape importante pour vérifier la pertinence des critères de filtrage définis lors du prétraitement. Les trajectoires GPS peuvent en effet présenter des différences importantes en termes de durée, de longueur, de nombre d'observations ou de fréquence d'acquisition. Certaines peuvent également contenir des observations aberrantes ou des interruptions d'enregistrement.

Plusieurs dimensions ont ainsi été étudiées : les caractéristiques temporelles des trajectoires, leur fréquence d'échantillonnage, les distances parcourues, les vitesses calculées entre observations successives ainsi que leur répartition entre périodes diurnes et nocturnes.

Cette exploration a également permis de mettre en évidence les différences entre les trois sources de données utilisées dans le projet. Les données de Paris et Londres présentent notamment une fréquence d'acquisition relativement régulière après préparation, tandis que les trajectoires issues de GeoLife présentent une fréquence temporelle beaucoup plus variable.

Les résultats de cette analyse ont servi à orienter les étapes suivantes du pipeline, notamment la définition des règles de filtrage, la construction des trajectoires individuelles et la préparation des données pour le *map matching*.

4.1 Analyse des caractéristiques temporelles des trajectoires

L'analyse temporelle permet de caractériser la fréquence d'acquisition des données et la durée des déplacements. Les trajectoires de Paris et Londres présentent, après préparation, un pas temporel d'environ une seconde pour une grande partie des observations. Les données GeoLife sont en revanche plus hétérogènes : les intervalles présentent une médiane de 2 secondes, une moyenne de 5,69 secondes et un 99^e percentile de 31 secondes. Certains intervalles sont beaucoup plus longs et correspondent à des interruptions de l'enregistrement. Ces différences de fréquence d'acquisition doivent être prises en compte lors de la comparaison des trajectoires et du calcul des variables cinématiques. Elles

justifient également un contrôle de la cohérence temporelle des observations lors du prétraitement.

4.2 Analyse de la distribution des vitesses

La distribution des vitesses a été étudiée sur les données brutes de Paris et de Londres afin d'identifier les valeurs caractéristiques des déplacements et de déterminer des seuils adaptés au filtrage des trajectoires.

Pour Paris, l'analyse porte sur environ **2,0 millions d'observations** réparties sur 17,079 traces. La vitesse médiane est de 1,68 m/s et le 95^e percentile atteint 15,05 m/s. La distribution présente toutefois des valeurs extrêmes, avec une vitesse maximale de 1,181,6 m/s, manifestement incompatible avec un déplacement piéton.




FIGURE 5 – Distribution de la vitesse pour les traces à Paris.

Pour Londres, environ **10,3 millions d'observations** provenant de 56,387 traces ont été analysées. La vitesse médiane est de 1,83 m/s et le 95^e percentile est de 14,03 m/s. Des valeurs extrêmes sont également observées, avec un maximum de 1,423,8 m/s.




FIGURE 6 – Distribution de la vitesse pour les traces à Londres.

Les distributions montrent une majorité de vitesses faibles, avec quelques valeurs extrêmes pouvant notamment résulter d'erreurs GPS ou temporelles.

La vitesse ne permet toutefois pas, à elle seule, d'identifier le mode de déplacement. Elle est donc utilisée comme **critère de cohérence** plutôt que comme méthode de classification.

Sur cette base, une borne supérieure de **4 m/s** et un seuil inférieur de **0,3 m/s** ont été retenus pour le filtrage initial des observations.

5 Prétraitement et construction des trajectoires

Les données de trajectoires utilisées dans cette étude proviennent de sources hétérogènes et ne peuvent pas être utilisées directement pour les analyses ultérieures. Elles peuvent notamment contenir plusieurs traces dans un même fichier, des interruptions d'enregistrement, des observations temporellement incohérentes ou des points GPS aberrants.

Une étape de prétraitement est donc nécessaire afin de transformer les données brutes en trajectoires individuelles, cohérentes et adaptées à l'analyse de la mobilité piétonne.

Le pipeline développé au cours du stage comprend plusieurs étapes successives : l'extraction des observations, la reconstruction et la segmentation des trajectoires, le contrôle des informations temporelles, le filtrage des observations et des trajectoires, puis la classification selon les périodes diurnes et nocturnes.

L'objectif de cette étape est d'obtenir un jeu de trajectoires suffisamment homogène pour permettre leur analyse exploratoire, leur recalage sur le réseau piéton et l'étude des caractéristiques de leur environnement urbain.

5.1 Extraction et reconstruction des trajectoires

La première étape du prétraitement consiste à extraire les observations GPS à partir des fichiers disponibles et à reconstruire les trajectoires individuelles.

Pour les données au format GPX, les fichiers sont analysés en tant que documents XML afin d'extraire, pour chaque observation, les coordonnées géographiques et l'horodatage lorsqu'il est disponible. Les points sont ensuite regroupés selon leur appartenance à une même trace.

Une difficulté particulière provient de la structure des données brutes. Certains fichiers peuvent contenir plusieurs trajectoires, tandis qu'une même trajectoire peut être divisée en plusieurs segments d'enregistrement. Les informations relatives aux éléments `trk`, `trkseg` et `trkpt` sont donc utilisées afin de reconstruire les différentes séquences de points.

Les trajectoires sont ensuite enregistrées sous forme de fichiers individuels afin de faciliter les étapes suivantes du pipeline. Pour Paris, cette organisation conduit notamment à plusieurs niveaux de préparation : les fichiers bruts sont d'abord séparés en trajectoires individuelles, puis les différents segments d'enregistrement sont traités séparément.

Cette étape permet ainsi de passer d'un ensemble de fichiers bruts potentiellement hétérogènes à une collection de trajectoires individuelles, chacune étant constituée d'une séquence ordonnée de positions GPS.

Pour les données GeoLife, la reconstruction repose directement sur la structure du dataset et sur les identifiants de trajectoire disponibles. Une procédure spécifique est donc appliquée, tout en conservant une représentation commune des trajectoires afin de permettre les traitements ultérieurs.

5.2 Nettoyage et cohérence temporelle

Après la reconstruction des trajectoires, une étape de contrôle temporel est réalisée afin de garantir la cohérence des séquences d'observations. Les points sont notamment triés selon leur horodatage afin de respecter l'ordre chronologique du déplacement.

Les observations ne disposant pas d'un horodatage exploitable sont écartées lorsque celui-ci est nécessaire aux traitements ultérieurs. Les doublons temporels et les séquences présentant des incohérences sont également contrôlés.

Une attention particulière est portée aux interruptions d'enregistrement. Une trajectoire peut en effet présenter des intervalles temporels importants entre deux observations successives. Ces interruptions sont conservées comme une information sur la qualité de l'enregistrement et prises en compte lors des étapes de filtrage, plutôt que d'être interprétées comme une portion continue du déplacement.

Cette étape permet d'obtenir des trajectoires temporellement cohérentes avant l'application des critères de sélection et de filtrage.

5.3 Segmentation et filtrage des trajectoires

Après la reconstruction des trajectoires, une étape de segmentation est réalisée afin d'identifier les interruptions importantes au sein d'une même séquence. Lorsqu'un écart temporel supérieur à **1 minute** et un écart spatial supérieur à **50 m** sont observés entre deux points successifs, la trajectoire est séparée en deux séquences distinctes. Cette règle permet d'éviter de considérer comme une seule trajectoire des portions de déplacement séparées par une interruption importante de l'enregistrement.

Un algorithme de filtrage est ensuite appliqué aux traces obtenues afin de sélectionner les trajectoires compatibles avec un déplacement à pied. Avant le calcul des indicateurs, les points présentant des valeurs aberrantes sont supprimés.

Le filtrage repose sur plusieurs critères complémentaires :

$$R_w \geq 0.65 \tag{14}$$

$$R_v \leq 0.03 \quad (15)$$

$$0.7 \leq V_{\text{med}} \leq 2.20 \quad (16)$$

$$P_{95}(v) \leq 3.5 \quad (17)$$

où R_w désigne le **ratio de marche**, R_v le **ratio de véhicule**, V_{med} la vitesse médiane de la trace et $P_{95}(v)$ le 95^e percentile des vitesses.

Les deux premiers critères permettent de prendre en compte la proportion du déplacement compatible avec la marche et celle compatible avec un déplacement en véhicule. Les critères portant sur la vitesse médiane et le 95^e percentile complètent cette information en imposant une plage de vitesses cohérente avec les déplacements piétons.

Une trace est conservée lorsqu'elle satisfait simultanément l'ensemble de ces conditions. Cette combinaison de critères permet ainsi de limiter la conservation de trajectoires correspondant à d'autres modes de transport tout en réduisant l'influence des observations aberrantes.




FIGURE 7 – Distribution des vitesses après filtrage pour Paris et Londres.

5.4 Classification des trajectoires selon la période

Après le filtrage des trajectoires, une classification selon la période de la journée est réalisée afin de distinguer les déplacements diurnes et nocturnes. La période nocturne est définie à partir du **crépuscule nautique**, dont les horaires sont calculés à partir de la date et de la localisation de chaque trajectoire à l'aide de la bibliothèque Python *Astral*.

La classification est réalisée au niveau de la trajectoire. Une trajectoire peut en effet commencer pendant la journée et se poursuivre après le début de la

période nocturne, ou inversement. Afin de tenir compte de ces situations, trois catégories sont définies : **jour**, **nuit** et **mixte**.

Une trajectoire est classée comme de jour lorsque plus de 70% de ses observations sont situées pendant la journée. Elle est classée comme de nuit lorsque plus de 70% des observations sont situées pendant la période nocturne. Dans les autres cas, elle est considérée comme **mixte**.

Cette classification permet ainsi d'éviter d'attribuer arbitrairement une trajectoire à une seule période lorsque celle-ci couvre une transition entre le jour et la nuit. Seules les trajectoires présentant une dominante suffisamment nette sont donc considérées comme strictement diurnes ou nocturnes pour les analyses comparatives.

6 Map matching

6.1 Introduction

Les trajectoires obtenues après le prétraitement sont constituées d'une succession de positions GPS. Ces positions ne correspondent toutefois pas directement aux éléments du réseau piéton : les erreurs de localisation peuvent notamment placer un point à proximité d'une rue différente de celle réellement empruntée. De plus, une trajectoire GPS constitue une observation discrète d'un déplacement continu.



FIGURE 8 – extrait des traces de piéton à Londres.

Afin d'identifier les itinéraires effectivement suivis par les piétons, une étape de **map matching** est donc réalisée. Cette opération consiste à associer les observations GPS aux éléments d'un réseau spatial de référence, en l'occurrence un réseau piéton construit à partir des données d'OpenStreetMap.

Le recalage permet ainsi de transformer une succession de positions géographiques en une succession de segments et de nœuds du réseau. Cette représentation est particulièrement importante pour la suite de l'étude, puisqu'elle permet de relier les trajectoires aux caractéristiques de l'environnement urbain rencontrées le long des itinéraires.

Le présent chapitre décrit la construction du réseau piéton utilisé, le principe de la méthode de recalage, les paramètres retenus ainsi que les résultats et les difficultés rencontrées lors de son application aux trajectoires de Paris et de Londres.

6.2 Construction du réseau piéton

Le *map matching* est réalisé à partir d'un réseau piéton construit avec les données d'**OpenStreetMap**. Le réseau est représenté sous la forme d'un graphe composé de nœuds et d'arêtes correspondant aux éléments du réseau accessibles aux piétons.

Un réseau est construit pour chacune des trois villes étudiées. Les graphes

sont ensuite sauvegardés au format GraphML, afin de pouvoir être réutilisés directement lors des différentes étapes du traitement sans avoir à reconstruire le réseau.

Ces réseaux constituent la référence spatiale utilisée pour associer les positions GPS des trajectoires aux portions de voirie correspondantes lors de l'étape de recalage.

6.3 Justification du choix du HMM

Le choix d'une méthode fondée sur un **modèle de Markov caché (HMM)** s'explique par la nature des données disponibles. Les trajectoires GPS sont constituées de positions ponctuelles et peuvent présenter des erreurs de localisation. Une simple association de chaque point GPS au segment de réseau le plus proche peut donc conduire à des correspondances incorrectes, notamment lorsque plusieurs rues sont proches les unes des autres.





FIGURE 9 – Exemples de recalage avec la projection sur le graphe.





FIGURE 10 – Exemples de recalage avec des MMC.

Le HMM permet de prendre en compte la trajectoire dans son ensemble plutôt que de traiter chaque observation indépendamment. Pour chaque position GPS, plusieurs éléments du réseau peuvent être considérés comme des candidats. La méthode évalue ensuite la cohérence des différentes séquences possibles en tenant compte à la fois de la proximité des observations avec le réseau et de la continuité du déplacement.

Cette approche est donc particulièrement adaptée au recalage de trajectoires GPS sur un réseau piéton, car elle permet de prendre en compte l'incertitude des observations tout en conservant la structure temporelle du déplacement.

Dans ce projet, le HMM est mis en œuvre à l'aide de la bibliothèque *Leuven Map Matching*, avec l'algorithme `DistanceMatcher`.

6.4 Paramétrage et stratégie de recalage

Le recalage est réalisé avec l'algorithme `DistanceMatcher` de la bibliothèque *Leuven Map Matching*. Les principaux paramètres utilisés sont :

- distance maximale : **30 m** ;
- distance maximale initiale : **30 m** ;
- bruit d'observation : **10 m** ;
- bruit d'observation non émissif : **30 m** ;
- bruit de distance : **15 m** ;
- facteur de longueur non émissive : **0,5** ;
- largeur maximale du treillis : **10 candidats**.

Une stratégie de recalage dans les deux sens de la trajectoire a également été adoptée afin d'améliorer la robustesse du résultat. Pour chaque trajectoire, un premier recalage est effectué dans le sens chronologique des observations, puis un second recalage est réalisé sur la trajectoire inversée.

Les deux résultats sont ensuite comparés à partir de leur taux de couverture, défini comme le rapport entre le nombre d'états obtenus après recalage et le nombre total de points de la trajectoire. Le résultat présentant le taux de couverture le plus élevé est conservé pour la suite du traitement.

Cette stratégie permet notamment de limiter les échecs ou les pertes de couverture pouvant apparaître selon le sens dans lequel la trajectoire est parcourue. Le recalage retenu est ensuite transformé en une succession d'arêtes du réseau, qui constitue la représentation finale de l'itinéraire suivi.

6.5 Application aux trajectoires

Le processus de recalage est appliqué aux trajectoires préalablement filtrées pour chacune des trois villes. Pour chaque trace, les positions GPS sont d'abord extraites, puis transmises au `DistanceMatcher` dans leur ordre chronologique.

Les trajectoires sont recalées dans les deux sens selon la procédure décrite précédemment. Le résultat présentant la meilleure couverture est ensuite conservé et converti en une succession d'arêtes du réseau piéton.

Les arêtes obtenues constituent alors la représentation spatiale de la trajectoire sur le réseau. Elles peuvent être utilisées dans les étapes suivantes pour associer chaque déplacement aux caractéristiques de son environnement urbain, notamment aux bâtiments, à l'éclairage public et aux indicateurs de visibilité.

6.6 Résultats du map matching

Le *map matching* a été appliqué aux trajectoires de Paris et de Londres. Les résultats sont évalués séparément pour le recalage dans le sens chronologique (*forward*), dans le sens inverse (*backward*), ainsi que pour la possibilité de réussir le recalage dans au moins un des deux sens.

À Paris, sur 983 trajectoires, le taux de réussite est de 60% dans le sens *forward* et de 61% dans le sens inverse. Au total, 71% des trajectoires peuvent être recalées dans au moins un des deux sens, tandis que les deux directions aboutissent à un recalage réussi pour 50,55% des trajectoires.

À Londres, les résultats sont légèrement supérieurs. Sur 8,431 trajectoires, le taux de réussite atteint 68% dans le sens *forward* et 67% dans le sens inverse. Un recalage est obtenu dans au moins une des deux directions pour 75% des trajectoires, tandis que les deux directions réussissent pour 59% des trajectoires.

Les taux de réussite diffèrent également selon la période de la journée. À Paris, les trajectoires nocturnes présentent un taux de réussite de 67,3% dans le sens *forward* et de 64,2% dans le sens inverse, contre respectivement 59,0% et 68% pour les trajectoires diurnes. À Londres, les taux sont de 76,9% et 67,1% pour les trajectoires nocturnes, contre 67,7% et 66,7% pour les trajectoires diurnes.

Ces résultats montrent que la stratégie de recalage dans les deux sens permet de récupérer une partie des trajectoires pour lesquelles une seule direction échoue. Ils montrent également une réussite globalement plus élevée pour les trajectoires nocturnes dans les deux villes.

6.7 Limites du map matching

Malgré l'utilisation d'un recalage dans les deux sens, le *map matching* présente certaines limites. Une proportion importante des trajectoires ne peut pas être correctement recalée sur le réseau piéton. Au total, environ 30% des trajectoires sont perdues lors de cette étape en raison d'échecs de recalage ou d'une couverture insuffisante.

Par ailleurs, certaines trajectoires obtenues après recalage sont nettement plus courtes que les trajectoires GPS originales. Le réseau disponible ou les correspondances retenues par l'algorithme ne permettent pas toujours de représenter l'intégralité du déplacement observé.

Ces limitations peuvent être liées à plusieurs facteurs, notamment aux erreurs de localisation GPS, à la structure du réseau piéton issu d'OpenStreetMap ou encore à l'absence de correspondance suffisamment cohérente entre certaines observations successives.

La perte d'une partie des trajectoires doit donc être prise en compte dans l'interprétation des résultats obtenus après recalage. Les analyses réalisées à partir du réseau concernent uniquement les trajectoires ayant pu être correctement recalées.

7 Construction du feature space

Après le recalage des trajectoires sur le réseau piéton, l'étape suivante consiste à caractériser quantitativement l'environnement urbain associé aux déplacements. L'objectif est de construire un **feature space** regroupant différentes variables décrivant les caractéristiques spatiales rencontrées le long des trajectoires.

Les variables utilisées proviennent de plusieurs sources de données, notamment des bâtiments, de leur hauteur, de l'éclairage public et de la morphologie urbaine. Elles sont associées aux trajectoires recalées afin de construire une représentation numérique de leur environnement.

La construction de ce *feature space* constitue une étape intermédiaire entre le traitement des trajectoires et l'analyse des déterminants des déplacements nocturnes. Les caractéristiques obtenues pourront ensuite être utilisées pour comparer les environnements associés aux trajectoires diurnes et nocturnes et rechercher les variables présentant les associations les plus importantes avec les comportements observés.

7.1 Données environnementales

Les données environnementales présentées au chapitre 3.2 sont utilisées ici pour caractériser l'espace traversé par les trajectoires. Elles sont préparées dans un système de coordonnées commun, puis associées aux points issus du recalage.

Les principales catégories considérées sont le bâti, la hauteur des bâtiments, l'éclairage public et les indicateurs de visibilité et de morphologie urbaine.

Afin de faciliter l'utilisation du GBA, un script a été développé pour automatiser le téléchargement des fichiers GeoPackage nécessaires au traitement. Le script permet notamment d'identifier les données correspondant à la zone géographique étudiée et de récupérer automatiquement les fichiers nécessaires. Cette approche rend le traitement réutilisable pour différentes villes, sans nécessiter de sélectionner manuellement les fichiers à télécharger.

Les données d'éclairage public sont également intégrées afin de caractériser l'environnement lumineux des trajectoires.

L'ensemble de ces données est ensuite préparé et mis dans un système de coordonnées commun avant d'être associé aux trajectoires recalées. Elles servent ainsi de base au calcul des différentes caractéristiques utilisées dans le *feature space*.

7.2 Extraction des caractéristiques autour des trajectoires

Après la préparation des différentes sources de données, les caractéristiques environnementales sont extraites à partir des trajectoires recalées. Les positions GPS originales sont conservées comme référence pour l'extraction des caractéristiques.

Pour chaque trajectoire, le nombre de points utilisés pour construire les caractéristiques reste ainsi identique au nombre de points de la trajectoire d'origine. Les points sont associés aux éléments du réseau obtenus après le *map matching*, ce qui permet de conserver la résolution spatiale de la trajectoire initiale tout en bénéficiant du recalage sur le réseau.

Pour chacun de ces points, les différentes sources de données spatiales sont ensuite utilisées afin de calculer les caractéristiques environnementales correspondantes. Les variables obtenues peuvent notamment décrire le bâti, la hauteur des bâtiments, la proximité de l'éclairage public ainsi que différents aspects de la visibilité et de la morphologie urbaine.

Les caractéristiques calculées pour l'ensemble des points sont ensuite regroupées afin de constituer le *feature space* utilisé dans les analyses suivantes.

7.3 Indicateurs morphologiques et de visibilité

En complément des caractéristiques liées au bâti et à l'éclairage public, des indicateurs décrivant la morphologie et la visibilité de l'espace urbain sont calculés autour des points des trajectoires. L'objectif est de caractériser la configuration spatiale de l'environnement dans lequel se déplace le piéton.

Ces indicateurs sont calculés à l'aide de **t4gpd**, une bibliothèque développée au sein du laboratoire et dédiée à l'analyse géométrique et spatiale des environnements urbains. Elle permet notamment de calculer des indicateurs de type *Sky View Factor* (SVF) ainsi que différentes caractéristiques issues d'isovistes. Le principe consiste à analyser l'espace visible depuis chaque point de la trajectoire en tenant compte de la géométrie du bâti environnant.

Les calculs sont réalisés à une hauteur de **1,6 m**, correspondant approximativement à la hauteur du point de vue d'un piéton. La portée maximale des rayons est fixée à **100 m** et **64 rayons** sont utilisés pour caractériser l'espace autour de chaque point.

Les calculs produisent un ensemble de **38 variables** décrivant différentes propriétés géométriques de l'environnement visible. Ces variables permettent notamment de caractériser la longueur des rayons dans le plan horizontal, leur distribution ainsi que la proportion d'espace ouvert visible depuis le point

considéré.

Parmi les variables obtenues figurent notamment :

- `min_raylen2D` : longueur minimale des rayons dans le plan horizontal;
- `avg_raylen2D` : longueur moyenne des rayons dans le plan horizontal;
- `med_raylen2D` : longueur médiane des rayons;
- `drift_raylen2D` : indicateur décrivant la distribution des longueurs de rayons;
- `H_raylen2D` : entropie associée aux longueurs de rayons;
- `avg_raylen25D` : longueur moyenne des rayons prenant en compte la dimension verticale;
- `svf_geom` : indicateur géométrique de *Sky View Factor*.

Ces indicateurs complètent ainsi les variables décrivant directement les objets urbains. Ils permettent de prendre en compte une dimension plus globale de l'environnement, en décrivant notamment son degré d'ouverture, la visibilité disponible autour du piéton et la configuration géométrique du bâti.

7.4 Construction du *feature space* final

Les différentes variables extraites à partir des données urbaines sont regroupées afin de constituer un *feature space* associé aux trajectoires. Chaque point échantillonné sur une trajectoire est ainsi décrit par un ensemble de caractéristiques environnementales calculées à partir de sa position et des données spatiales disponibles.

Le jeu de données final combine plusieurs catégories de variables :

- des variables décrivant le **bâti**, notamment les caractéristiques géométriques des bâtiments environnants;
- des variables relatives à la **hauteur du bâti**;
- des variables décrivant la **proximité de l'éclairage public**;
- des indicateurs de **morphologie et de visibilité** calculés avec *t4gpd*.

La construction du *feature space* permet ainsi de passer d'une représentation purement géographique des trajectoires à une représentation numérique de leur environnement. Les trajectoires peuvent alors être comparées non seulement selon leur géométrie ou leur localisation, mais également selon les caractéristiques urbaines associées aux espaces traversés.

Une attention particulière est portée à la conservation de la correspondance entre les points des trajectoires et leurs caractéristiques environnementales. Chaque point échantillonné conserve ainsi son association avec la trajectoire et sa période de déplacement, notamment la distinction entre les observations diurnes et nocturnes.

Avant les analyses statistiques, les variables présentant des valeurs manquantes ou ne fournissant pas d'information exploitable sont écartées. C'est notamment le cas de la variable `h_over_w`, qui n'est pas retenue dans le *feature space* final.

Le jeu de données ainsi construit constitue la base des analyses présentées dans le chapitre suivant, consacrées à l'étude des relations entre les caractéristiques de l'environnement urbain et les déplacements nocturnes.

8 Analyse des caractéristiques associées à la marche nocturne

8.1 Introduction

Les étapes précédentes ont permis de construire un jeu de données associant les trajectoires piétonnes à différentes caractéristiques de leur environnement urbain. Après le prétraitement des trajectoires, leur classification selon la période de déplacement, leur recalage sur le réseau piéton et l'extraction des variables environnementales, il est désormais possible d'étudier les relations entre ces caractéristiques et les déplacements nocturnes.

L'objectif de ce chapitre est d'identifier les variables de l'environnement urbain qui présentent des différences entre les trajectoires diurnes et nocturnes. L'analyse porte notamment sur les caractéristiques liées au bâti, à sa morphologie ainsi qu'à la visibilité de l'espace urbain.

Dans un premier temps, une analyse descriptive permet de comparer les distributions des différentes variables entre les deux groupes. Des tests statistiques sont ensuite utilisés afin d'évaluer la significativité des différences observées.

Les résultats sont interprétés comme des **associations statistiques** entre les caractéristiques de l'environnement et la période de déplacement. Ils ne permettent donc pas d'établir une relation causale directe entre une caractéristique urbaine et le choix d'un itinéraire nocturne.

Cette analyse permet néanmoins d'identifier les caractéristiques de l'environnement qui présentent les différences les plus importantes entre les déplacements diurnes et nocturnes et qui peuvent ainsi constituer des pistes pour des analyses plus approfondies.

8.2 Comparaison des caractéristiques environnementales entre le jour et la nuit

Une première analyse consiste à comparer les caractéristiques environnementales associées aux trajectoires diurnes et nocturnes. Pour chaque variable, la médiane, la moyenne et la *p-value* du test statistique sont calculées séparément pour les deux groupes.

8.2.1 Résultats pour Paris

Le tableau présente les variables pour lesquelles les différences entre les trajectoires de jour et nocturnes sont les plus significatives.

	feature	day_median	night_median	day_mean	night_mean	p_value
6	svf_geom	0.698620	0.568312	0.665115	0.585150	0.002917
4	H_raylen2D	2.423817	2.756299	2.145513	2.428320	0.004435
2	med_raylen2D	68.284488	47.322917	63.403219	53.676750	0.006324
5	avg_raylen25D	64.115070	52.993174	61.824720	54.107065	0.007772
1	avg_raylen2D	63.326849	50.874413	60.999595	53.271875	0.008117
8	isovist_perimeter	656.959797	635.836452	642.875963	620.164580	0.008461
7	isovist_area	16362.196890	11699.471612	16095.120181	13243.890989	0.008578
3	drift_raylen2D	14.648550	16.216345	14.986775	17.119251	0.027249
0	min_raylen2D	16.112904	11.600420	24.005981	17.653923	0.044869
9	streetlight_count	30.546070	34.174603	55.274084	56.876967	0.062747

FIGURE 11 – Comparaison des caractéristiques environnementales entre le jour et la nuit à Paris

À Paris, plusieurs indicateurs de visibilité présentent des différences statistiquement significatives entre les deux périodes. Les différences les plus faibles en termes de *p-value* concernent notamment svf_geom, H_raylen2D, med_raylen2D et avg_raylen25D. La variable streetlight_count ne présente en revanche pas de différence statistiquement significative au seuil de 5%.

8.2.2 Résultats pour Londres

Les résultats obtenus pour Londres sont présentés dans le tableau.

	feature	day_median	night_median	day_mean	night_mean	p_value
6	svf_geom	0.932317	0.757752	0.860930	0.733433	1.050962e-37
7	isovist_area	21120.609042	9063.789702	20098.020880	12774.459428	9.193781e-36
2	med_raylen2D	86.380515	36.043344	71.036199	48.595316	2.049663e-35
1	avg_raylen2D	76.026211	44.982273	71.694379	52.640196	5.091996e-35
5	avg_raylen25D	76.975392	46.374228	72.460173	53.762206	5.432882e-35
4	H_raylen2D	1.769029	3.006234	1.586856	2.471660	8.258742e-35
0	min_raylen2D	28.669342	10.988158	47.473823	23.324480	5.003852e-34
3	drift_raylen2D	10.206070	13.594887	9.868383	13.326209	4.943695e-14
8	isovist_perimeter	643.051826	651.173511	663.683031	649.567962	9.819150e-02

FIGURE 12 – Comparaison des caractéristiques environnementales entre le jour et la nuit à Londres

À Londres, les différences sont particulièrement marquées pour les indicateurs de visibilité. Les variables svf_geom, isovist_area, med_raylen2D, avg_raylen2D et avg_raylen25D présentent toutes des *p-values* très faibles. À l'inverse, isovist_perimeter ne présente pas de différence statistiquement significative au seuil de 5%.

8.2.3 Synthèse des résultats

Dans les deux villes, les différences statistiquement significatives concernent principalement les indicateurs décrivant la visibilité et la configuration géométrique de l'environnement urbain. Plusieurs variables présentent des valeurs plus faibles pour les trajectoires nocturnes, notamment le *Sky View Factor*, les longueurs de rayons et la surface des isovistes.

Ces résultats mettent donc en évidence une association entre la période du déplacement et plusieurs caractéristiques morphologiques de l'environnement. Cette association ne doit toutefois pas être interprétée comme une relation causale : les différences observées peuvent également être liées à la localisation des trajectoires, à leur répartition spatiale ou à d'autres facteurs non contrôlés dans cette analyse.

8.3 Analyse des principales différences observées

Les résultats montrent que les différences entre les trajectoires diurnes et nocturnes concernent principalement les indicateurs de visibilité et de morphologie urbaine.

À Paris comme à Londres, le *Sky View Factor* (`svf_geom`), les longueurs de rayons (`avg_raylen2D`, `med_raylen2D`, `avg_raylen25D`) ainsi que la surface des isovistes (`isovist_area`) présentent des valeurs généralement plus faibles pour les trajectoires nocturnes. Ces différences sont statistiquement significatives dans les deux villes.

Les résultats concernant l'éclairage public sont moins marqués. À Paris, la variable `streetlight_count` ne présente pas de différence statistiquement significative au seuil de 5% ($p = 0,062747$). De même, le périmètre des isovistes (`isovist_perimeter`) présente des résultats différents selon la ville : la différence est significative à Paris ($p = 0,008461$), mais pas à Londres ($p = 0,0982$).

Globalement, les indicateurs de visibilité apparaissent donc comme les variables présentant les différences les plus systématiques entre les trajectoires diurnes et nocturnes dans les données étudiées. Ces résultats indiquent une association entre la période du déplacement et certaines caractéristiques morphologiques de l'environnement, sans toutefois permettre d'établir une relation causale.

9 Interprétation, limites et perspectives

9.1 Interprétation des résultats

Les résultats montrent une différence entre les environnements associés aux trajectoires de jour et nocturnes. Parmi les indicateurs étudiés, le *Sky View Factor* géométrique (*svf_geom*) constitue un indicateur particulièrement intéressant pour interpréter cette différence, car il fournit une mesure directement liée à la proportion de ciel visible depuis le point considéré.

À Paris comme à Londres, la valeur de *svf_geom* est plus élevée pour les trajectoires de jour que pour les trajectoires nocturnes. À Paris, la médiane passe de 0,699 le jour à 0,568 la nuit, tandis qu'à Londres elle passe de 0,932 à 0,758.

Ces résultats suggèrent que, dans les données étudiées, les trajectoires de jour sont davantage associées à des espaces présentant une plus grande ouverture visuelle, tandis que les trajectoires nocturnes sont davantage associées à des espaces où la portion de ciel visible est plus faible.

Les autres indicateurs de visibilité, notamment les longueurs de rayons et la surface des isovistes, présentent également des différences entre les deux périodes. Cependant, plusieurs de ces variables sont fortement liées entre elles et au *Sky View Factor*, puisqu'elles décrivent différentes dimensions d'une même configuration spatiale. Le *svf_geom* est donc privilégié ici pour faciliter l'interprétation du phénomène observé, plutôt que de considérer chacune de ces variables comme une information indépendante.

Cette tendance est observée dans les deux villes étudiées. Elle doit toutefois être interprétée comme une association statistique et non comme une relation causale : les résultats montrent une différence dans les environnements associés aux trajectoires diurnes et nocturnes, mais ne permettent pas à eux seuls de déterminer si l'ouverture de l'espace influence directement le choix de l'itinéraire.

Nos résultats restent néanmoins exploratoires. La comparaison réalisée porte sur les environnements associés aux trajectoires et ne permet pas de déterminer si les caractéristiques observées influencent directement le choix des itinéraires nocturnes. Les différences peuvent également être liées à la localisation des trajectoires, à la structure du réseau piéton ou à la répartition spatiale des déplacements entre les deux périodes.

Ainsi, le principal apport de cette analyse est de mettre en évidence une association entre la période du déplacement et certaines caractéristiques morphologiques de l'environnement urbain. Elle fournit une première base pour approfondir l'étude des facteurs susceptibles d'être associés aux choix de déplacement nocturne.

9.2 Limites des données et du traitement

Plusieurs limites doivent être prises en compte dans l'interprétation des résultats. Elles concernent notamment le volume et la représentativité des trajectoires, la nature collaborative des données utilisées, le *map matching* ainsi que la construction des caractéristiques environnementales.

9.2.1 Volume et représentativité des trajectoires

Le nombre de trajectoires disponibles constitue une première limite importante. Malgré plusieurs milliers de trajectoires à Londres, le nombre de trajectoires nocturnes reste relativement faible par rapport aux trajectoires diurnes. Cette différence est encore plus marquée à Paris, où seules **80 trajectoires nocturnes** sont disponibles après le filtrage, contre 813 trajectoires diurnes.

Cette répartition déséquilibrée limite notamment la robustesse des comparaisons entre les deux périodes. Les résultats obtenus pour les trajectoires nocturnes reposent sur un nombre d'observations plus faible et peuvent donc être davantage sensibles à la composition particulière de l'échantillon.

Par ailleurs, les trajectoires disponibles ne constituent pas nécessairement un échantillon représentatif de l'ensemble des déplacements piétons réalisés dans les villes étudiées. Les personnes enregistrant et partageant leurs déplacements peuvent présenter des profils, des habitudes de déplacement ou des usages différents de ceux de la population générale.

9.2.2 Biais liés aux données OpenStreetMap

Les trajectoires issues d'OpenStreetMap présentent également une limite liée à leur nature collaborative. Les données sont produites et partagées par des utilisateurs et ne résultent pas d'un protocole d'échantillonnage contrôlé.

Cette caractéristique peut introduire un biais de sélection dans les trajectoires disponibles. Certaines zones, certains types de déplacements ou certaines périodes peuvent être davantage représentés que d'autres en fonction des pratiques des contributeurs. La distribution spatiale des trajectoires ne peut donc pas être considérée comme représentative de la mobilité piétonne de l'ensemble de la population.

Cette limite est particulièrement importante pour l'étude de la marche nocturne. Une concentration des trajectoires dans certains quartiers ou sur certains types d'itinéraires peut notamment influencer les différences observées entre les environnements diurnes et nocturnes.

9.2.3 Limites du prétraitement et du map matching

Les trajectoires GPS peuvent présenter des erreurs de localisation, des interruptions d'enregistrement ou des variations importantes de fréquence entre les observations. Les règles de segmentation et de filtrage permettent de limiter ces problèmes, mais ne permettent pas de garantir une reconstruction parfaite des déplacements.

Le *map matching* constitue également une étape limitante du pipeline. Un recalage est obtenu dans au moins une des deux directions pour environ 71% des trajectoires à Paris et 75% à Londres. Une partie des trajectoires est donc exclue des analyses reposant sur le réseau piéton.

Cette sélection peut elle-même introduire un biais : les trajectoires qui ne peuvent pas être recalées ne sont pas nécessairement réparties aléatoirement dans l'espace ou selon les caractéristiques des déplacements. Les résultats obtenus après *map matching* doivent donc être interprétés comme portant sur les trajectoires effectivement recalées et non sur l'ensemble des déplacements initiaux.

9.2.4 Hétérogénéité des données environnementales

Enfin, les données utilisées pour caractériser l'environnement urbain ne sont pas identiques pour toutes les villes. Les sources disponibles, leur résolution, leur couverture et leurs méthodes de production peuvent différer entre Paris et Londres.

Cette hétérogénéité doit être prise en compte lors de la comparaison des résultats entre les deux villes. Une différence observée entre les distributions peut en effet être liée à la fois aux caractéristiques réelles des environnements urbains et aux différences entre les sources de données utilisées.

L'ensemble de ces limites montre que les résultats doivent être considérés comme une **première analyse exploratoire**. Ils permettent d'identifier des associations intéressantes entre les trajectoires et leur environnement, mais leur généralisation à l'ensemble de la mobilité piétonne nécessite des données plus nombreuses, plus représentatives et acquises selon un protocole contrôlé.

9.3 Perspectives et améliorations

Les limites identifiées au cours de l'étude permettent de dégager plusieurs pistes d'amélioration pour poursuivre ce travail.

Une première perspective concerne la constitution d'un jeu de données plus important et plus représentatif. L'augmentation du nombre de trajectoires nocturnes permettrait notamment de réduire l'influence de la composition parti-

culière de l'échantillon et d'améliorer la robustesse des comparaisons entre les périodes diurne et nocturne. L'utilisation de données collectées selon un protocole contrôlé pourrait également permettre de limiter les biais liés au caractère collaboratif des données utilisées dans cette étude.

Une deuxième piste concerne le map matching. L'amélioration de la couverture du réseau piéton, l'ajustement des paramètres de recalage et l'étude d'autres méthodes pourraient permettre de réduire le nombre de trajectoires exclues. Une comparaison systématique entre plusieurs algorithmes de recalage permettrait également d'évaluer la sensibilité des résultats à cette étape du pipeline.

La construction du feature space pourrait également être approfondie. L'utilisation de données environnementales homogènes entre les différentes villes permettrait de faciliter les comparaisons. D'autres caractéristiques pourraient par ailleurs être intégrées, notamment des informations plus détaillées sur l'éclairage, la configuration du réseau piéton, les usages du sol ou encore les équipements présents dans l'espace public.

Enfin, une analyse plus approfondie pourrait chercher à contrôler les effets liés à la localisation des trajectoires. Les différences observées entre les déplacements diurnes et nocturnes peuvent en effet être liées à la distribution spatiale des trajectoires. Des méthodes permettant de comparer des trajectoires réalisées dans des environnements similaires, ou de contrôler explicitement la localisation et les caractéristiques du réseau, permettraient de mieux isoler les associations spécifiques à la période nocturne.

10 Conclusion générale

Ce stage avait pour objectif d'étudier les relations entre les trajectoires piétonnes et les caractéristiques de l'environnement urbain, avec une attention particulière portée aux déplacements nocturnes. Un pipeline complet a été développé, depuis le prétraitement et le filtrage des trajectoires GPS jusqu'à leur recalage sur le réseau piéton et la construction d'un *feature space* décrivant leur environnement. L'analyse des trajectoires diurnes et nocturnes met en évidence des différences dans les environnements associés aux deux périodes. Le *Sky View Factor* présente notamment des valeurs plus élevées pour les trajectoires diurnes, à Paris comme à Londres, suggérant une association entre les déplacements diurnes et des espaces présentant une plus grande ouverture visuelle. Ces résultats restent toutefois exploratoires et ne permettent pas d'établir une relation causale avec le choix des itinéraires. Enfin, les limites liées au nombre de trajectoires nocturnes, au biais de sélection des données collaboratives, au *map matching* et à l'hétérogénéité des sources doivent être prises en compte. Le travail réalisé constitue néanmoins une première base

méthodologique pour poursuivre l'étude de la marche nocturne et développer une analyse plus robuste des relations entre trajectoires piétonnes et environnement urbain.

Annexes

Références bibliographiques

- [1] GitHub du stage, https://github.com/NAIROMEGA/nighttime_walkability
- [2] ANR, Projet ANR-LUNNE, ANR-22-CE22-0004, <https://anr.fr/Projet-ANR-22-CE22-0004>
- [3] Meert, W., Verbeke, M., “HMM with Non-Emitting States for Map Matching”, European Conference on Data Analysis (ECDA), Paderborn, Germany, 2018.
- [4] Leuven Map Matching, Documentation, <https://leuvenmapmatching.readthedocs.io/>
- [5] Zhu-Xlab, GlobalBuildingAtlas, <https://github.com/zhu-xlab/GlobalBuildingAtlas>
- [6] Astral, Documentation, <https://sffjunkie.github.io/astral/>
- [7] Belhadi, A., Djenouri, Y., Srivastava, G., Djenouri, D., Lin, J. C.-W., Fortino, G., “Deep Learning for Pedestrian Collective Behavior Analysis in Smart Cities : A Model of Group Trajectory Outlier Detection”, Information Fusion, vol. 65, pp. 13–20, 2021.
- [8] Fang, K., Wang, X., Chen, L., Zhang, Z., Furuya, N., “Research on the Correlation between Pedestrian Density and Street Spatial Characteristics of Commercial Blocks in Downtown Area : A Case Study on Shanghai Tianzifang”, Journal of Asian Architecture and Building Engineering, vol. 18, no. 3, pp. 233–246, 2019.
- [9] Jeong, I., Choi, M., Kwak, J., Ku, D., Lee, S., “A Comprehensive Walkability Evaluation System for Promoting Environmental Benefits”, Scientific Reports, vol. 13, no. 1, 16183, 2023.
- [10] Johansson, M., Rosén, M., Küller, R., “Individual Factors Influencing the Assessment of the Outdoor Lighting of an Urban Footpath”, Lighting Research Technology, vol. 43, no. 1, pp. 31–43, 2011.
- [11] Messa, F., Scarponi, L., Abdelfattah, L., et al., “Modeling Women’s Perceived Level of Safety at Night in Milan”, Journal of Transport Geography, vol. 127, 104243, 2025.
- [12] Usman, S. M., Khattak, A. J., Patwary, A. L., “Nighttime Pedestrian Safety in Different Communities : Application of Artificial Intelligence Techniques”, Journal of Safety Research, vol. 94, pp. 340–361, 2025.
- [13] Wang, X., Liu, Z., Wu, Y., Liu, T., “Using a Virtual Reality Approach to Study the Impact of Nighttime Lighting on Pedestrian Crossing Behavior”, Virtual Reality, vol. 29, no. 3, 101, 2025.
- [14] Zaki, M. H., Sayed, T., “Automated Analysis of Pedestrian Group Behavior in Urban Settings”, IEEE Transactions on Intelligent Transportation Sys-

tems, vol. 19, no. 6, pp. 1880–1889, 2018.

[15] Vintsyuk, T. K., “Speech Discrimination by Dynamic Programming”, Cybernetics, 1968.

[16] Geolife, Microsoft,
<https://www.microsoft.com/en-us/research/publication/geolife-gps-trajectory-dataset-user-guide/>

[17] Documentation t4gpd, Thomas Leduc, CRENAU
<https://github.com/thomas-leduc/t4gpd>

[18] M. L. Benedikt, “To take hold of space : isovists and isovist fields,” Environ. Plan. B Plan. Des., vol. 6, no. 1, pp. 47–65, 1979.

[19] JORF n°25 du 30 janvier 2005, p. 1625 - texte n° 43 - Vocabulaire des sciences et techniques spatiales (liste de termes, expressions et définitions adoptés) [archive] », sur legifrance.gouv.fr, 30 janvier 2005

[20] David H Douglas et Thomas K. Peucker, « Algorithms for the reduction of the number of points required to represent a digitized line or its caricature », Cartographica : The International Journal for Geographic Information and Geovisualization, University of Toronto Press, vol. 10, no 2, 1973, p. 112-122 [

21] OpenStreetMap(OSM), traces <https://www.openstreetmap.org/traces/>

Résultats

Paris




FIGURE 13 – Boxplots des résultats obtenus pour les différentes caractéristiques à Paris.

Londres




FIGURE 14 – Boxplots des résultats obtenus pour les différentes caractéristiques à Londres.

Clustering

L'analyse des trajectoires a également fait l'objet d'une exploration par différentes méthodes de *clustering*. L'objectif était d'identifier des groupes de trajectoires présentant des caractéristiques similaires et d'évaluer leur intérêt pour l'étude des déplacements nocturnes.

Plusieurs représentations des trajectoires ont été considérées, notamment à partir des couples origine–destination et de mesures de similarité entre trajectoires. Des méthodes de regroupement telles que **DBSCAN** et la **Dynamic Time Warping (DTW)** ont notamment été testées.

Résultats

Les regroupements obtenus produisent des clusters de tailles parfois importantes. Ce résultat s'explique notamment par la diversité des distances parcourues : des trajectoires relativement longues peuvent partager certaines caractéristiques avec un grand nombre d'autres trajectoires et ainsi être regroupées dans des ensembles importants.

La taille des clusters ne permet donc pas, à elle seule, d'identifier des profils de déplacement homogènes. Les groupes obtenus peuvent également dépendre fortement de la représentation choisie et des paramètres utilisés pour définir la similarité entre trajectoires.




FIGURE 15 – Quelques clusters définies PAR DTW

Les approches testées permettent ainsi d'explorer différentes structures présentes dans les données, mais ne conduisent pas à une classification suffisamment claire et interprétable pour être intégrée à l'analyse principale.

Limites

Une difficulté importante réside dans la définition de la similarité entre deux trajectoires. Celle-ci peut dépendre de leur origine et destination, de leur géométrie, de leur longueur ou encore de leur dynamique temporelle. Une mesure unique peut donc difficilement rendre compte de l'ensemble de ces dimensions.

La présence de trajectoires longues constitue également une difficulté pour les méthodes fondées sur leur similarité géométrique. Des trajectoires de longueurs différentes peuvent présenter des portions communes ou des structures similaires sans pour autant correspondre au même type de déplacement. L'analyse par couples origine–destination présente également une limite liée à la nature des données utilisées. Une partie des trajectoires correspond à des déplacements en boucle, notamment dans les parcs : le point de départ et le point d'arrivée sont alors proches, voire identiques, malgré une trajectoire pouvant être longue et complexe.

Ces trajectoires peuvent être regroupées avec d'autres déplacements présentant des origines et destinations similaires, alors que leurs parcours sont très différents. Cette situation limite donc la capacité du clustering origine–destination à représenter la structure réelle des déplacements.

La présence fréquente de ces trajectoires en boucle peut également constituer un biais lié aux données OpenStreetMap utilisées. Les traces disponibles peuvent en effet refléter certains usages particuliers de la plateforme et ne constituent pas un échantillon représentatif de l'ensemble des déplacements piétons.